Technische
Hochschule
Rosenheim

Fakultät für Informatik

Studiengang Informatik

Erstellung einer standardisierten Material-Kostengliederung für Projekte einer Bausoftware mittles Natural Language Processing

Bachelor Thesis

von

Florian Weidner

Datum der Abgabe: tt.mm.jjjj

Erstprüfer: Prof. Dr. Marcel Tilly

Zweitprüfer: Prof. Dr. Johannes Jurgovsky

Eigenständigkeitserklärung / Declaration of Originality

Hiermit bestätige ich, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Die Stellen der Arbeit, die dem Wortlaut oder dem Sinn nach anderen Werken (dazu zählen auch Internetquellen) entnommen sind, wurden unter Angabe der Quelle kenntlich gemacht.

I declare that I have authored this thesis independently, that I have not used other than the declared sources / resources, and that I have explicitly marked all material which has been quoted either literally or by content from the used sources.

Rosenheim, den tt.mm.jjjj

Vor- und Zuname

Abstract

Anhand der vorliegenden wissenschaftlichen Arbeit sollte ein Konzept für die hierarchische Strukturierung von Materialien aus Industy Foundation Classes (IFC)-Dateien für eine Programmerweiterung der Bausoftware ORCA AVA erarbeitet werden. Dafür sollen passende Natural Language Processing (NLP)-Algorithmen für die Strukturierung ausgewählt werden. Es wurden verschiedene Algorithmen nach definierten Kriterien der Messbarkeit evaluiert und passende ausgewählt. Materialangaben bestehen meistens aus Stichpunkten mit nur einem oder wenigen Wörtern und fallen somit in die Kurztext-Klassifizierung. Zusätzlich müssen Fachbegriffe richtige verarbeitet werden. Die Materialstrukturierung wurde in die Textklassifizierung und eine weitere Feinstrukturierung aufgeteilt. Für die Textklassifizierung stellte sich ein Maximum Entropy Model mit dem Stochastic dual coordinated ascent (SDCA)-Optimierungsalgorithmus trotz Kurztext-Klassifizierung mit einer Genauigkeit von 88,2 % als beste Wahl heraus. Bei der Feinstrukturierung wird eine domänenspezifisches *fastText*-Modell trainiert, um die Bedeutung der Wörter, trotz Stichpunkte und Fachbegriffen, bei der Vektorisierung der Materialien mitzugeben. So können die Materialien mit Density-Based Spatial Clustering of Applications with Noise (DBSCAN)-Clustering weiter strukturiert werden. Dieses Vorgehen schneidet besser ab, als das Nutzen des ChatGPT-Modells von OpenAI. Für das Ausführen der Strukturierung wurde ein Webservice implementiert, um die Machine-Learning-Modelle zentral nutzen zu können und keine Pythonumgebung für die ORCA AVA installiert werden muss.

Schlagworte: NLP, Machine Learning, IFC, BIM, ML.NET, fastText, DBSCAN

Inhaltsverzeichnis

Abbildungsverzeichnis

1 Einleitung

Inhalt dieser wissenschaftlichen Arbeit ist das automatische Erstellen einer Material-Kostengliederung aus einer IFC-Datei mithilfe von NLP zur Erweiterung einer Bausoftware. Diese Bausoftware ist die ORCA AVA aus dem mittelständigen Softwarehaus „ORCA Software GmbH“ aus Neubeuern. In diesem Kapitel soll eine kurze Einführung über die „ORCA Software GmbH“ und das Produkt ORCA AVA gegeben werden. Außerdem wird die Motivation für die Programmerweiterung und die wissenschaftliche Vorgehensweise dieser Arbeit beschrieben.

1.1 Ausgangssituation

Die im Titel beschriebene Bausoftware ist die ORCA AVA aus dem Softwarehaus „ORCA Software GmbH“. Dieses wurde im Jahr 1990 von Dipl.-Ing. Siegfried Tille und Dipl.-Ing. Heinz Nießen gegründet. Der Hauptsitz des Unternehmens ist in Neubeuern, bei Rosenheim. Das Unternehmen ist auf die Produktentwicklung von Software für die Baubranche spezialisiert. Im Vordergrund stehen die Ausschreibungssoftware ORCA AVA und die Ausschreibungstext-Plattform AUSSCHREIBEN.DE (ADE). Ziel der Entwicklung ist es die Auschreibung, Vergabe und Abrechung (AVA) eines Bauvorhabens für Planer, Architekten und Bauingenieure zu vereinfachen. Der Leitfaden ist, Software zu entwickeln, die jeder versteht, intuitiv bedienbar ist, einen optimalen Workflow gewährleistet und viele Import- und Exportmöglichkeiten für den Datenaustausch bietet. Diese Arbeit fokussiert sich auf eine Erweiterung der ORCA AVA. Sie ist für alle Architektur- und Ingenieurbüros, Wohnungsbaugesellschaften, Unternehmen und Behörden zur einfachen Abwicklung von Bauprojekten mit Ausschreibung, Vergabe und Abrechnung. Zusätzlich bildet sie das Kostenmanagement von solchen Projekten ab. Die Software ist außerdem BIM fähig und bietet Deutsches Institut für Normung e. V. (DIN) zertifizierte Schnittstellen für den Datenaustausch an. Neben der ORCA AVA gibt es den IFC-Manager als eigene Instanz, der IFC-Modelle anzeigen kann. Die ORCA AVA kann dann Mengen aus dem Gebäudemodell übernehmen. Es stehen drei verschiedene Editionen der Software zur Verfügung. Die ORCA AVA Starter Edition (SE), die ORCA

AVA Professional Edition (PE) und die ORCA AVA Enterprise Edition (EE). Die aktuellste Version ist die 25.0.

Technisch wird die ORCA AVA in .NET entwickelt. Ein Großteil der Anwendung besteht noch aus Visual Basic (VB) Code. Alle neuen Komponenten und Erweiterungen werden in C# implementiert. Neue Graphical User Interface (GUI)-Komponenten werden dementsprechend mit Windows Presentation Foundation (WPF) entwickelt. WPF ist ein .NET Framework für das Erstellen von Windows Applikationen mit grafischer Benutzeroberfläche von Microsoft. (vgl. Microsoft, 2022*d*) Die ORCA AVA und der IFC Manager (siehe Unterabschnitt 2.2.3) laufen in eigenen Prozessen und kommunizieren auf Prozessebene in der lokalen Umgebung.

1.2 Motivation

Ziel der „ORCA Software GmbH“ ist es, BIM noch mehr in die ORCA AVA zu integrieren. BIM bedeutet, dass die Planung von Bauprojekten vollständig auf digitaler Basis durchgeführt wird. Für jeden Projektbeteiligten besteht somit jederzeit Zugriff auf alle projektrelevanten Daten wie Kosten, Mengen und Zeitabläufen. Somit können Baukosten einfacher ermittelt und der Bauprozess besser überwacht werden. In Abbildung 1.1 ist zu sehen, dass BIM ein relevanter Begriff in der Baubranche ist. Die Verwendung in der Praxis ist allerdings noch nicht weit verbreitet. (vgl. Thomas, Baumanns and Dr. Philipp-Stephan, Freber and Dr. Kai-Stefan, Schober and Dr. Florian, Kirchner, 2016, p. 20) Mit dem „IFC First“ Ansatz ist das langfristige Ziel der ORCA AVA, das Thema BIM noch mehr abzudecken. Aus den Daten eines 3D-Gebäudemodells soll automatisch ein Ausschreibungstext generiert werden können. Wenn ein IFC-Bauteile demnach schon alle Informationen beinhalten, soll damit eine Position mit Kurztext, Langtext, Menge, Preis und vordefinierten Kostengliederungen in den Programmteil Bauelemente der ORCA AVA übernommen werden können. Der erste Teil davon ist die Übernahme der Baumaterialien aus einer IFC-Datei. Diese bietet die erste Kostengliederung für den „IFC First“ Ansatz. Die Übernahme von weiteren Daten aus dem IFC-Modell können darauf aufgebaut werden. Aufgrund der hohen Relevanz des Themas, spricht das Ganze viele Kunden an und stellt somit ein effektives Werbemittel für den Verkauf der Software dar.

Ein weiterer Trendbegriff, der mit der Programmerweiterung abgedeckt werden soll, ist „Künstliche Intelligenz“ und „Maschinelles Lernen“. Das Suchinteresse der beiden Themen ist in Abbildung 1.2 zu sehen. Die Werte geben das Google-Suchinteresse relativ zum höchsten Punkt im angegebenen Zeitraum an. Der Begriff „Maschinelles Lernen“

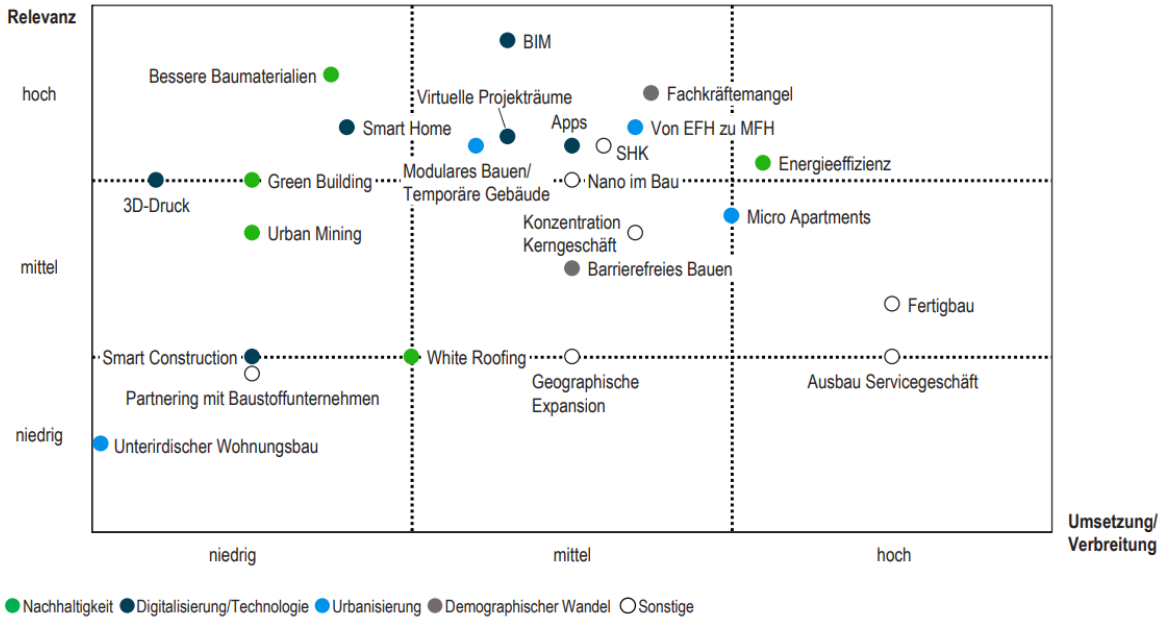

Abbildung 1.1: Megatrends Nachhaltigkeit und Digitalisierung in der Bauwirtschaft. Bilder aus (vgl. Thomas, Baumanns and Dr. Philipp-Stephan, Freber and Dr. Kai-Stefan, Schober and Dr. Florian, Kirchner, 2016, p. 20)

hat seit Anfang 2015 ein steigendes Suchinteresse. Bei „Künstliche Intelligenz“ ist das Suchinteresse von Anfang 2017 bis Ende 2021 konstant hoch. Der starke Anstieg ab November 2022 ist signifikant und korreliert wahrscheinlich mit der Veröffentlichung des Chatbots ChatGPT, wodurch auch Menschen außerhalb der Informatik erreicht wurden. Man erkennt insgesamt, dass das Interesse über die letzten Jahre stetig ansteigt. Die Abdeckung dieser Begriffe ist seit geraumer Zeit ein Wunsch der Vertriebsseite für den noch besseren Verkauf der Software. Die neue Programmerweiterung wäre der erste Einsatz von maschinellem Lernen. Es ist also zusätzlich auch ein Pilotprojekt in der ORCA AVA Entwicklung, um sich mit Machine-Learning-Algorithmen vertraut zu machen und Erfahrungen in diesem Themengebiet zu sammeln.

Durch die genannten Punkte ist die Programmerweiterung dem Kano-Modell nach als Begeisterungsfeature zuzuordnen. Die Kundenzufriedenheit steigt also exponentiell mit dem Erfüllungsgrad der Anforderung. (siehe Abbildung 1.3) Mit der Zeit wandelt sich es dann erst in ein Leistungsfeature und irgendwann in ein Basisfeature. (vgl. Hölzing, 2008, p. 3-4) Es besteht also die Motivation die Erweiterung möglichst exklusiv zur Verfügung zu stellen. Es eignet sich somit sehr für die ORCA AVA EE Edition.

(a) Suchinteresse: Künstliche Intelligenz

(b) Suchinteresse: Machine Learning

Abbildung 1.2: Google Suchinteresse der beiden Begriffe „Künstliche Intelligenz“ und „Maschinelles Lernen seit 2004 bis 2023

1.3 Ziel der Arbeit

Die Erstellung der Materialkostengliederung hängt hauptsächlich von den genutzten Algorithmen ab, welche die Materialien strukturieren. In dieser Arbeit soll neben dem Konzept für die Programmerweiterung, demnach vor allem der Algorithmus für die Strukturierung der Materialien erarbeitet werden. Um die Anforderungen aus Abschnitt 3.2 umsetzten zu können, muss dafür zuvor ein Ziel formuliert werden. Die Zieldefinition für diese Arbeit wird nach der SMART Technik definiert. Dabei muss ein Ziel folgende Eigenschaften haben:

- Spezifisch
- Messbar
- Attraktiv
- Realisierbar
- Terminiert

Anhand dieser Kriterien wurde folgendes Ziel definiert:

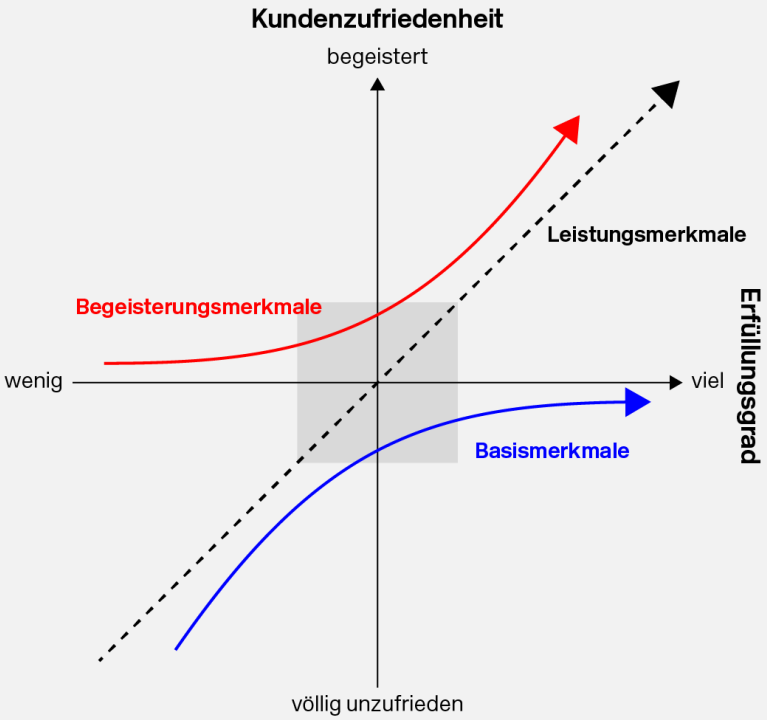

Quelle: https://dmexco-lightsails-media.s3.eu-central-1.amazonaws.com/wp-content/uploads/2021/01/04112832/Kano-Modell.png (Accessed: 2023-2-24)

Abbildung 1.3: Kano Modell der Kundenzufriedenheit

Ziel. *Bis zum 15.06.2023 werden für die Implementierung passende Algorithmen nach den Kriterien der Messbarkeit (siehe Unterabschnitt 3.2.1) ausgewählt. Dazu wird ein „Draftprojekt“ mit allen vollständigen funktionalen Anforderungen für die ORCA AVA implementiert. Zusätzlich sollen die Maßnahmen zur Qualitätssicherung (Kapitel 7) durchgeführt werden.*

1.4 Wissenschaftliche Vorgehensweise

Im Folgenden wird die wissenschaftliche Vorgehensweise der Arbeit aufgezeigt. In Kapitel 1 wurde bereits die Ausgangssituation beschrieben, das Entwickeln der Programmerweiterung motiviert und des Ziel dieser Arbeit definiert. Im nächsten Kapitel, Kapitel 2, werden Grundlagen erläutert, auf die diese Arbeit aufbaut. Im anschließenden Kapitel 3 sollen die Problemstellung und Anforderungen analysiert werden. Danach (Kapitel 4) wird eine Lösung für die Problemstellung theoretisch konzipiert und verschiedene mögliche Algorithmen erläutert und analysiert. Hierfür wird der Ablauf in

die Textklassifizierung und die Feinstrukturierung aufgeteilt. In Kapitel 5 werden die Algorithmen für diese beiden Schritte jeweils gegenübergestellt und nach den definierten Kriterien der Messbarkeit ausgewählt. Kapitel 7 zeigt die genutzten Maßnahmen der Qualitätssicherung auf. Am Ende wird das Ergebnis bewertet und ein Ausblick gegeben.

2 Grundlagen

In diesem Kapitel werden die Grundlagen im Bereich der fachspezifischen Themen, Technik und Projektmanagement vermittelt. Das soll Verständnis für die folgenden Kapitel schaffen. Zuerst geht es um das Projektmanagement. Anschließend geht es um das Format IFC, dessen Geschichte und dessen Nutzungsmöglichkeiten für diese Arbeit. Außerdem wird die Struktur und der Nutzen einer Kostengliederung in der ORCA AVA veranschaulicht.

2.1 Projektmanagement

Bevor auf technische und fachliche Aspekte von IFC und Kostengliederungen eingegangen wird, folgt die Einführung in das Projektmanagements mit SCRUM und Development Operations (DevOps).

2.1.1 Vorgehensmodell

Das Projekt wurde mithilfe agiler Softwareentwicklung durchgeführt. Im ORCA AVA Entwicklungsteam wird das SCRUM Modell verwendet. Die Entwicklung der Produkterweiterung in dieser Arbeit läuft in diesem SCRUM-Prozess.

Definition 1 (Scrum)**.** *„Scrum is a lightweight framework that helps people, teams and organizations generate value through adaptive solutions for complex problems. “ (vgl. Ken and Jeff, 2020, p. 3)*

SCRUM verwendet einen iterativen, inkrementellen Ansatz. So kann Sprint für Sprint aus gewonnenen Erfahrungen der Entwicklungsablauf optimiert werden. (vgl. Ken and Jeff, 2020) Product Owner in der ORCA AVA Entwicklung ist die „ORCA Software GmbH“, in Vertretung des Produktmanagement-Teams. Die Umsetzung der Sprint-Ziele wird von einer Person implementiert.

2.1.2 DevOps

Die Bezeichnung DevOps vereint die beiden Praktiken „Development“(Entwicklung) und „Operations“(Vorgänge). Die traditionelle Trennung von Entwicklung und Softwarebetrieb führt oft zu Interessenskonflikten. Entwickler wollen stetig die Software verbessern und der Betrieb will Änderungen vermeiden, um die Stabilität des Systems zu gewährleisten. Durch DevOps entsteht ein Softwareentwicklungsprozess, den man durch Praktiken wie Continous Integration, Continous Delivery, Continous Deployment, automatisiertes Teste, Infrastructure-as-Code und automatische Veröffentlichungen beschleunigt. DevOps steht auch für eine Entwicklungskultur mit offener Zusammenarbeit, Kommunikation, Transparenz und Eingestehen von Fehlern, um Konflikte im Team zu vermeiden. (vgl. Beetz and Harrer, 2021) Im Entwicklungsteam der ORCA AVA wird diese Praktik umgesetzt. Die technischen Hilfsmittel, die für den DevOps Prozess verwendet werden, sind in Abschnitt 7.2 beschrieben.

2.2 Industy Foundation Classes (IFC)

Die Daten für die Material-Kostengliederung werden aus einem digitalem Gebäudemodell entnommen. Der öffentliche internationale Standard (ISO 16739-1:2018) für Gebäudemodelle ist IFC. (vgl. *Industry Foundation Classes*, 2017) Dieser wird auch in der bestehenden ORCA AVA benutzt, um den Ausschreibungsprozess zu unterstützen. IFC Dateien können geöffnet, das 3D-Modell angezeigt und Informationen über das Modell in die Hauptsoftware übernommen werden.

2.2.1 Geschichte

IFC ist die Hauptleistung der *buildingSMART International Ltd.*. Die non-profit Organisation will mit der Spezifikation den BIM Prozess fördern und voranbringen. (vgl. Grutters, 2022) Angefangen hat die Organisation als der Verein *Industrieallianz für Interoperabilität IAI e. V.* mit Sitz in Berlin. 1994 startete die Entwicklung an dem offenen Datenmodellstandard IFC. Dieser sollte die Anforderungen der Industrie an Interoperabilität gerecht werden und eine gemeinsame Basis zum Austausch von Informationen durch verschiedenen Anwendungen schaffen. Im Zusammenhang mit BIM sollten Daten lesbar, editierbar für verschiedene Systeme durch den Bauprozess und kompletten Lebenszyklus eines Gebäudes geteilt werden. (vgl. Laakso and Kiviniemi, 2012) Nach einigen Prototypen wurde 1999 IFC 2.0 veröffentlicht. Diese wurde bis 2007 mit der Version 2.3.0.1 stetig verbessert. Die Version 2.3 wird auch in heutigen Projekten

noch verwendet. 2013 wurde IFC4 veröffentlicht, welche mit der Version 4.0.2.1 die aktuellste, offizielle IFC Version ist. Das Format wird weiterhin stetig weiterentwickelt. Neue Versionen stehen schon vor einer Abstimmung der International Organization for Standadization (ISO). (vgl. van Berlo, 2022) Es gibt folgendermaßen aktuell zwei offizielle Versionen. Beide werden in der Praxis benutzt und sind, wie in Unterabschnitt 2.2.3 beschrieben, mit der ORCA AVA kompatibel.

2.2.2 Format

Das IFC Format kodiert folgende Daten:

- Identität, Semantik, Attribute und Relationen von Objekten
- Abstrakte Konzepte wie Performance oder Kosten
- Prozesse wie z.B.Installationen und Operationen
- Personen wie z.B. Eigentümer oder Lieferanten

Die Spezifikation kann also für das Bauen, Betreiben oder Nutzen eines Gebäudes genutzt werden. IFC ist ein Implementierungs-Unabhängiges Datenmodell, welches in verschiedenen Umgebungen und elektronischen Formaten benutzt werden kann. Es kann beispielsweise in eine relationales Datenbankschema gegossen oder auch als Dateiformat implementiert werden. Das weitverbreiteste Format ist Standard for the exchange of product model data (STEP) Physical Format (SPF) (vgl. Laakso and Kiviniemi, 2012; Grutters, 2022). SPF ist das kompakteste Format für den dateibasierten Import und Export von IFC-Dateien. Die Dateiendung des Formates ist „*.ifc*“. Des Weiteren kann IFC als Extensible Markup Language (XML) oder ZIP Datei verwendet werden. (vgl. Grutters, 2022)

2.2.3 Verwendung

> „Today, IFC is typically used to exchange information from one party to another for a specific business transaction.“ (Grutters, 2022)

In der ORCA AVA wird IFC für das Einlesen und Übernehmen von Maßen und Mengen in die Ausschreibung verwendet. Es vereinfacht den Prozess, die in der Computer-aided design (CAD)-Software erstellten Daten einfach in die Leistungsverzeichnisse der ORCA AVA zu überführen. Die ORCA AVA kann IFC-Dateien einlesen. Im IFC Manager wird das 3D-Modell dann angezeigt. In dem geöffneten Fenster gibt es einige fachliche

Ansichten, die jegliche IFC-Daten nochmal fachlich abstrahieren. In den Ansichten können zum Beispiel bestimmte Maße oder die Anzahl verschiedener Bauteile, die aus dem IFC-Modell ermittelt werden, in die ORCA AVA übernommen werden. Auch alle definierten Eigenschaften eines Bauteils sind in der Eigenschaften-Ansicht sichtbar. Hier kann man auch die Materialbezeichnung des Bauteils finden, die im Modell hinterlegt ist. In Abbildung A.1 ist die Oberfläche des IFC Managers zu sehen. Man sieht die Materialangabe rechts unten im Eigenschaftenfeld unter dem 3D-Modell.

Für das Arbeiten mit IFC-Dateien wird die open-source Bibliothek *xbim-toolkit* (Lockley et al., 2017) verwendet. Die .NET Bibliothek kann IFC-Dateien lesen, schreiben und anzeigen. Außerdem unterstützt es bei der Berechnung von komplexer Geometrie, um die Modelldaten für Analysen nutzbar zu machen. Die Entwicklung der Bibliothek startete 2007 und läuft seit 2009 in Zusammenarbeit mit der Norhumbria Untiversity. Mittlerweile bildet es die Standards IFC Version 2.3 (IFC2x3) und IFC Version 4 (IFC4) zu 100% ab. Zudem bietet es an, auch IFC2x3 Modelle über das IFC4 Interface anzuprogrammieren. Somit können mit einer Codebasis beide Formate abgebildet und unterstützt werden. (vgl. Xbim Ltd., n.d.)

2.2.4 Möglichkeiten für die Materialangabe eines Bauteils

In einem IFC-Modell können Materialien auf unterschiedliche Weise einem Bauteil zugewiesen werden. Die Spezifikation bietet die Klasse *IfcMaterial*. Diese bildet fachlich ein Material ab. Es hat die Attribute Name, Description und Category.(vgl. buildingSMART International Ltd., 2017*a*) Eine Instanz von *IfcMaterial* kann mit einem Element oder Elementtyp über die *IfcRelAssociatesMaterial* verbunden werden. Diese Zuweisung kann über verschiedene Weisen stattfinden. In Abbildung 2.1 ist eine direkte Zuweisung über das *IfcRefAssociatesMaterial* zu sehen. Hier hängt das *IfcMaterial* direkt am Element. Bei einer Platte mit mehreren Schichten kann das *IfcMaterial* auch wie in Abbildung A.2 zu sehen an einem *IfcMaterialLayerSet* zugewiesen sein. Jede Schicht hat hier seine eigene Dicke und eigene Materialangabe. Ein Träger kann das *IfcMaterial* über ein *IfcMaterialProfileSet* abgebildet haben. (siehe Abbildung A.4) Bei einer Tür können verschiedene Materialien des Rahmens und der Verglasung über das *IfcMaterialConstituentSet* abgebildet werden. (siehe Abbildung A.5) (vgl. buildingSMART International Ltd., 2017*b*) Zusätzlich gibt es noch ältere Möglichkeiten Materialangaben an ein Element zu binden. In IFC2x3 gibt es die Klasse *IfcMaterialList* (vgl. Thomas et al., 2007). Diese Möglichkeit ist deprecated, in der Praxis kommt das IFC2x3 Format noch regelmäßig vor. Die *IfcMaterialList* muss also auch beachtet werden. Neben verschiedenen

Verbindungen zu *IfcMaterial* hat jedes Element bei IFC auch verschiedene Property Sets. Property Sets sind Container, die Eigentschaften je nach ihrem Namensattribut enthalten. Einige Property Sets sind in der Spezifikation des IFC Standards enthalten. Es können auch zusätzlich benutzerdefinierte Property Sets erfasst werden. Diese können auch Informationen über das Material eines Elements enthalten. (vgl. buildingSMART International Ltd., 2017*c*) Das PropertySet *Pset_MaterialConcrete* weist darauf hin, dass es sich z.B um Beton handelt.

Die Qualität der Materialkostengliederung hängt somit am Ende maßgeblich von den Materialangaben in der IFC-Datei ab. Wenn Materialspezifikationen fehlen, ist auch das Ergebnis der Materialstrukturierung fehlerhaft.

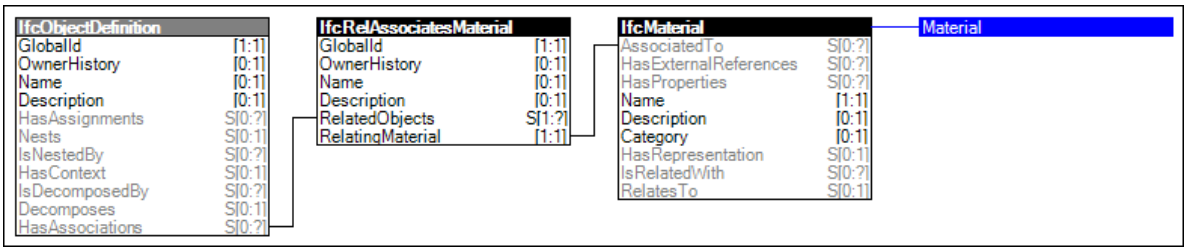

Abbildung 2.1: Material Single Association

2.3 Das Format Kostengliederung in der ORCA AVA

Die Kostengliederung bietet eine Struktur, um Gesamtkosten einer Baumaßnahme in Kostengruppen unterteilt auswerten zu können. Logisch zusammengehörende Kosten können so in eine Kostengruppe (KG) zusammengerechnet werden. Außerdem handelt es sich beim Aufbau um eine Baumstruktur, wodurch Kostengruppen hierarchisch addiert werden können. In Abbildung A.6 ist ein Beispiel einer Kostengliederung mit Materialien zu sehen. Der Gliederungspunkt *Mineralisch* wird in die Unterpunkte *Mauerwerk*, *Beton*, *Dachziegel* und *Kies* unterteilt. Um die Kosten aller Mineralien zu erfassen, können die Kosten der Unterpunkte für den Gliederungspunkt *Mineralisch* addiert werden. Bei einem Bauprojekt kann man so Kosten über alle Projektphasen vergleichen. Von der Kostenschätzung über die Ausschreibung bis zur Rechnungsfreigabe. So können Kostenauswertungen nach den verschiedenen Kostengruppen durchgeführt werden. In einem ORCA AVA Projekt kann man verschiedene Kostengliederungen definieren. Es existieren bereits Standardkostengliederungen beim Erstellen eines neuen Projektes. Zusätzlich können neue Kostengliederungen erstellt oder importiert werden.(vgl. ORCA Software GmbH, n.d.)

3 Problemstellung und Anforderungen

Im folgenden Kapitel werden die Problemstellung und Anforderungen aufgeführt, um das Projekt einzugrenzen. Diese kommen vom Auftraggeber, der „ORCA Software GmbH“ selbst.

3.1 Problemstellung

Die Problemstellung entsteht aus der Ausgangssituation (Abschnitt 1.1) und der Motivation (Abschnitt 1.2) der Bausoftware ORCA AVA. Der BIM Prozess soll noch mehr in die Software integriert werden. Deswegen wurde sich die Programmerweiterung der Materialkostengliederung gewünscht, um den ersten Schritt zu „BIM First“ zu schaffen. Die Problemstellung dieser Arbeit bezieht sich der dementsprechenden Umsetzung dieser Programmerweiterung:

Problemstellung 1. *Wie lässt sich am besten eine Liste vom Materialbezeichnungen in eine hierarchische Material-Kostengliederung strukturieren?*

Da es sich hier um eine offene Frage handelt, sind Spielräume für die Antwort offen. Es soll ein Konzept und eine Architektur für die Programmerweiterung entstehen. Um ein fachlich richtiges Ergebnis der Strukturierung zu erreichen, ist aber vor allem folgende Problemstellung wichtig:

Problemstellung 2. *Welcher NLP Algorithmus eignet sich am besten für das Klassifizieren und Strukturieren von Material-Daten?*

Bei dieser offenen Frage, soll am Ende ein Algorithmus oder eine Kombination aus einer Auswahl ausgewählt werden. Um verschiedene Ansätze und Algorithmen vergleichen zu können, benötigt man Kriterien der Messbarkeit. Diese werden in Unterabschnitt 4.2.2 und Unterabschnitt 4.3.1 definiert. So kann man neben der Berücksichtigung der Anforderungen den geeignetsten Algorithmus auswählen, um die Problemstellungen 1 und 2 zu lösen.

3.2 Anforderungen

Alle definierten Anforderungen kommen vom Projektmanagement Team der ORCA Software GmbH und dem Teamleiter der ORCA AVA Entwicklung. Die Gesamtheit von Anforderungen kann in funktionale Anforderungen, Leistungsanforderungen, spezifische Qualitätsanforderungen und Randbedingungen unterteilt werden.(vgl. Glinz, 2007) Durch die beschriebenen Anforderungen aus diesem Abschnitt entstand das beschriebene Ziel der Arbeit (siehe Abschnitt 1.3)

3.2.1 Funktionale Anforderungen

Definition 2 (Funktionale Anforderung)**.** *„A functional requirement is a requirement that pertains a functional concern.“(Glinz, 2007)*

Wie in Definition 2 beschrieben, geht es bei einer funktionalen Anforderung um die Funktion einer Software. Die im Mittelpunkt stehende Funktion ist die Erstellung der hierarchischen Materialstruktur (Anforderung 1). Nach dem Importieren der Materialstruktur aus einer IFC-Datei soll bei der Übernahme von Mengen die Materialkostengliederung automatisch zugewiesen werden (Anforderung 2). Zusätzlich sollen die Ergebnisse von Anforderung 1 sich stetig verbessern. Dafür soll eine Möglichkeit geschafft werden, dass Nutzer der ORCA AVA Verbesserungen eintragen können und sich somit den Trainingsdatenbestand erweitert und verbessert (Anforderung 3).

Anforderung 1. *Aus einer Liste von Materialbezeichnungen soll eine hierarchische Baumstruktur entstehen, welche in einer ORCA AVA Kostengliederung benutzt werden kann.*

Anforderung 2. *Bei der Übernahme einer Menge aus dem IFC Manager soll die passende Material-Kostengruppe zugewiesen werden.*

Anforderung 3. *Bei einem falsch zugewiesenem Material in der generierten Kostengliederungsstruktur soll eine persistente, dauerhafte Verbesserung des Benutzers möglich sein.*

Die funktionalen Anforderungen werden noch nicht direkt in die ORCA AVA integriert. Wie im Ziel der Arbeit erläutert, wird ein Draftprojekt zur Demonstration der Funktionen dienen. Somit kann zuerst überprüft werden, ob die gewünschte Anforderung 1 fachlich gut genug ist, um sie in die Hauptsoftware zu integrieren. Ein Vorschlag zur Integration in die Oberfläche der ORCA AVA wird am Ende in Abschnitt 8.3 gegeben.

3.2.2 Weitere Anforderungen

Neben den funktionalen Anforderungen gibt es vor allem technische Anforderungen an die Programmerweiterung. Diese wurden vom Teamleiter der ORCA AVA Entwicklung gestellt:

Anforderung 4. *Die Programmerweiterung soll wenn möglich in .NET (C#) implementiert werden. Darüber hinaus ist auch das Nutzen von Python möglich.*

Die technische Einschränkung der Anforderung 4 macht den Code und die Programmerweiterung für die ORCA Software GmbH wartbar. C# ist die Hauptsprache der Firma. Durch das dementsprechende Wissen in der Entwicklung, kann bei Fehlerbehebungen eine erneute Einarbeitungszeit vermeidet werden. Zusätzlich gibt es auch schon ein Modul für AUSSCHREIBEN.DE (ADE), das Pythoncode verwendet.

Anforderung 5. *Die Materialstrukturierung soll mit der Erweiterung der Datengrundlage immer besser gemacht werden können.*

Durch das Einlesen neuer IFC-Dateien von Benutzern, werden immer neue unklassifizierte Materialbezeichnungen gesammelt, die die Datengrundlage erweitern. Somit müssen neue Begriffe klassifiziert werden können, um das Modell stetig zu verbessern. Dementsprechend müssen Künstliche Intelligenz (KI)-Modelle auch immer wieder neu trainierbar sein. ORCA Internen Mitarbeiter sollen also eine Möglichkeit zum Klassifizieren der Daten zur Verfügung stehen haben.

4 Theoretische Konzeption

In diesem Kapitel wird ein theoretisches Konzept für das Lösen der Problemstellung erstellt und begründet. Zuerst wird das allgemeine Konzept vorgestellt. Dann werden mögliche Algorithmen erläutert und evaluiert, wie sie zu den Anforderungen passen. Im Folgekapitel werden die Algorithmen miteinander verglichen und der geeignetste ausgewählt.

4.1 Grundlegende Architektur und Vorgehensweise

In diesem Abschnitt wird das erarbeitete Konzept für die Erweiterung vorgestellt und begründet. In Abbildung 4.1 ist ein Anwendungsfalldiagramm der neuen Funktionen zu sehen. Die Anwendungsfälle des Benutzers der ORCA AVA decken sich mit den schon beschriebenen funktionalen Anforderungen in Unterabschnitt 3.2.1. In Abbildung A.8, A.9 und A.10 sind Flussdiagramme für diese drei Anwendungsfälle zu sehen. Die zusätzlichen Anwendungsfälle der AVA Entwickler ergeben sich aus Anforderung 5.

Das Ergebnis des Hauptanwendungsfalles der Materialstrukturierung ist abhängig von den Inhalten der IFC-Datei. Durch die Nutzung verschiedener CAD-Programme und eigene Vorlieben bei der Materialangabe der ORCA AVA Benutzer entstehen viele unterschiedliche Inhalte bei der Materialangabe. Um diese komplexe Problemstellung zu vereinfachen, werden Materialien zuerst nach dem „Teile-und-hersche“ Verfahren in Oberkategorien klassifiziert. In Abbildung A.3 sind die Oberkategorien mit Beispielen aufgelistet. So müssen anschließend nur noch eine kleinere Liste von Materialien einer Oberkategorie jeweils weiter hierarchisch strukturiert werden.

In Abbildung A.7 ist ein Verteilungsdiagramm mit allen relevanten Objekten zu sehen. Auf dem lokalem Computer des Benutzers laufen die beiden Prozesse der ORCA AVA und des IFC Managers. Die ORCA AVA kommuniziert mit einem Webserver über Representational State Transfer (REST). Dieser verwaltet die anhängende Structured Query Language (SQL) Datenbank und übernimmt das Ausführen der funktionalen Anforderungen.

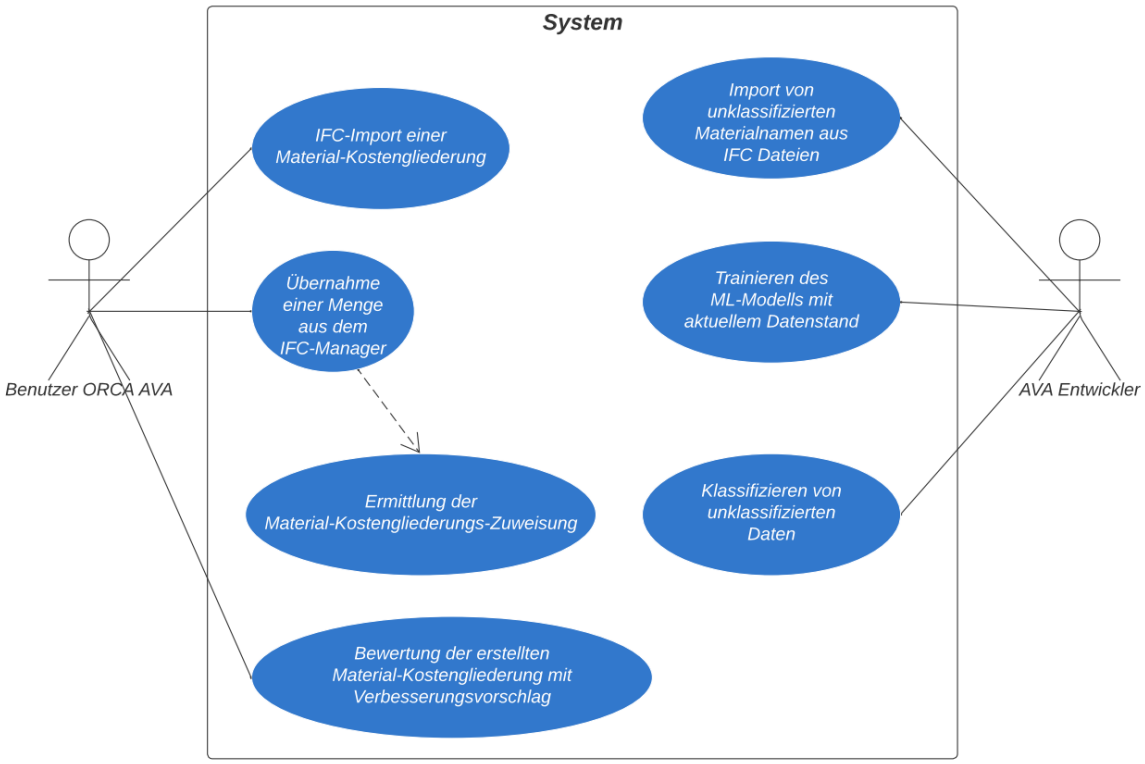

Abbildung 4.1: Anwendungsfalldiagramm

4.1.1 Implementierung als Web-Service

Für die Materialstrukturierung ist ein neuer Webservice vorgesehen, mit dem die ORCA AVA kommunizieren kann. Dies bietet einige Vorteile:

- Der Import greift immer auf das aktuellste KI-Modell zu, welches zentral verwaltet werden kann
- Wegen der nötigen Verwendung von Python muss nicht bei jedem Client eine lauffähige Pythonumgebung vorhanden sein oder durch das Setup installiert werden.
- Neue Materialbezeichnungen und Klassifizierungen werden direkt zentral in der Datenbank persistiert.
- Eine Änderung/Verbesserung der Datengrundlage kann durch automatisches Trainieren direkt zu einem verbessertem KI-Modell für alle Nutzer führen.

Für die ORCA AVA bestehen schon Services für die Bereitstellung von News, die Lizenzierung oder das Updaten der Software. Durch die Vorgabe der ORCA Software GmbH wird der Service mit dem Framework ASP.NET implementiert. ASP.NET ist

ein Open-Source und Plattform-unabhängiges Web-Framework für die Entwicklung cloudbasierter Anwendungen wie Web-Applikationen, Internet of Things (IoT)-Apps oder mobile Backends. (vgl. .NET Foundation and Contributors, n.d.). Die Architektur dieses Services entspricht dementsprechend den schon existierenden Services.

Daten werden über den Service in einem SQL-Datenbankserver gespeichert. Hier werden auch die ORCA Software GmbH internen Standards verwendet. Daten für den Material-Kostengliederungs-Import sind in der Tabelle *Materials* persistiert. Die Tabellendokumentation ist in Abbildung 4.2 zu sehen. Zusätzlich bestehen Tabellen für die Autorisierung der Zugriffe auf den Service.

Name	Typ	Beschreibung	Besonderheit
Id	INT	Generierte Id	Primary Key
MaterialBezeichnung	NVARCHAR(100)	Materialname	
MaterialCategory	INT	Zugewiesene Material-Überkategorie (siehe enum: MaterialCategory)	
IfcFile	NVARCHAR(255)	interner Pfad zu IFC-Datei, die diese MaterialBezeichnung enthält	
BauteilGuid	NVARCHAR(100)	GUID des Bauteiles in der IfcFile angegebenen IFC-Datei	
Created	DATETIME2	Datum der Erstellung dieses Datensatztes	Default Value: getutcdate()
Updated	DATETIME2	Datum der Aktualisierung dieses Datensatztes (z.B Klassifizierung)	

Abbildung 4.2: Dokumentation der Tabelle *Materials* der Datenbank

4.1.2 Konzept der Materialstrukturierung

Der Ablauf der Materialstrukturierung ist in drei Schritten aufgeteilt. Materialien werden nach dem Einlesen zuerst nach dem Preprocessing in übergeordnete Kategorien klassifiziert. Danach wird jede Überkategorie nochmals feiner strukturiert. Dieser Ablauf ist in Abbildung 4.3 anhand eines Beispiels zu sehen. Am Ende entsteht bei erfolgreicher Feinstrukturierung eine Baumstruktur mit einer Tiefe von drei. Falls nach der Zuweisung in die Überkategorien mehr als 2 Materialien in der gleichen Kategorie sind, wird weiter fein-strukturiert.

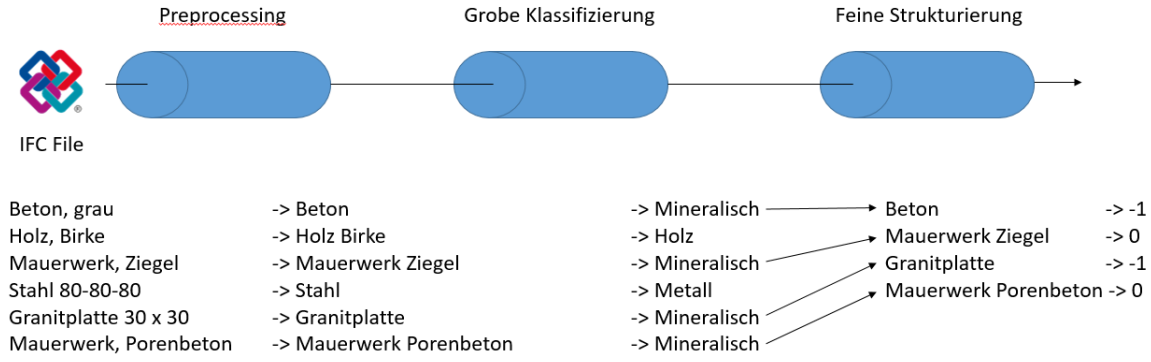

Abbildung 4.3: Ablauf der Strukturierung mit Beispiel

Bei der Strukturierung von Materialien gibt es einige NLP spezifische Probleme, die gelöst werden müssen.

Problemstellung 3. *Bei den Materialangaben handelt es sich um sehr kurze Stichpunkte aus nur einem oder wenigen Wörtern. (z. B. Metall, Edelstahl - gebürstet)*

Problemstellung 3 ist ein bekanntes, aber noch wenig erforschtes Problem in der Textklassifizierung. Textklassifizierungen stützen sich meistens auf Textrepräsentationen. Diese machen den Text durch Vektorisieren für den Klassifizierungsalgorithmus erst lesbar. Bei der Repräsentation von Texten haben kurze Texte folgende Nachteile:

- Kurzen Texten fehlt es an Kontext. Kontextbezogene Worteinbettungen wie z.B. Word2Vec führen folgendermaßen zu unbrauchbaren Textrepräsentationen für die Textklassifizierung.
- Kurze Texte entsprechen nicht immer der Syntax der natürlichen Sprache
- Kurze Texte sind in der Regel mehrdeutig, weil sie Polyseme und Tippfehler enthalten. (vgl. Wang et al., 2017)

Um das Problem zu überwinden, schlagen Wang et al. (2017) und Chen et al. (2019) vor, mehr Syntax und Semantik aus den kurzen Texten zu erfassen, in dem man, mithilfe einer bekannten Wissensbasis, die Texte mit Merkmalen anreichert. Die Informationen aus dem Text alleine, reichen nicht aus, um die Bedeutung des Textes in einer Textrepräsentation gut darzustellen. Bie (2019) nutzt unter anderem Wikipedia2Vec, um mit diesem Modell eine Textrepräsentation der Kurztexte zu ermitteln. Durch den mitgegebenen Kontext über das Wikipedia2Vec Modell wird so dem Wort seine Bedeutung der Textklassifizierung mitgegeben.

Problemstellung 4. *In den Materialangaben kommen viele Fachbegriffe aus der Baubranche vor.*

Ein weiteres Problem ist Problemstellung 4. Laut Nooralahzadeh et al. (2018) gibt es viele vortrainierte Worteinbettungs-Modelle, die sich aber auf den allgemeinen Bereich der Sprache fokussieren. Diese können Fachbegriffe oft schlecht verarbeiten, da die zum Trainieren genutzten Texte, diese Wörter nicht beinhalten.

Wie diese Probleme gelöst beziehungsweise umgangen werden, wird in den jeweiligen Abschnitten der verschiedenen analysierten Algorithmen in Abschnitt 4.2 und Abschnitt 4.3 erläutert.

4.1.3 Konzept für das Auslesen von Materialien aus einer IFC Datei

Bevor jegliche Klassifizierung und Strukturierung stattfinden kann, müssen die Materialien erst aus der IFC-Datei extrahiert werden. In Unterabschnitt 2.2.4 wurden bereits die theoretischen Möglichkeiten der Materialangabe in der IFC-Spezifikation aufgezählt.

Über schon vorhandenen Abstraktion des *xbim-toolkit* (siehe Unterabschnitt 2.2.3) kann eine IFC-Datei eingelesen werden. Über das instanziierte Objekt `IfcProject` kann dann auf alle Daten der Datei zugegriffen werden. Hier wird ein neuer `MaterialsManager` als Attribut des `IfcProject` hinzugefügt. Über die Methode `Enumerable<Material> GetMergedMaterials()` im `MaterialsManager` können alle Materialangaben aus einer IFC-Datei ausgelesen werden. Die Methode iteriert über jeden bekannten Materiallink mit seinem jeweiligen Objekt, teilt diese Links nach ihrem jeweiligen Materialtyp (z. B. LayerSet) auf und liest die Materialbezeichnungen entsprechend dem Materialtypen aus. Am Ende liefert die Methode also alle Materialbezeichnungen in einer List mit der jeweiligen Globally Unique Identifier (GUID) des Bauteiles. Das Extrahieren der Materialien passiert clientseitig in der ORCA AVA. So muss dem Service nicht eine ganze Datei, sondern lediglich die Liste der Material-Zeichenketten übergeben werden. Zusätzlich spart man sich die Zeit des Einlesens der IFC-Datei, wenn diese schon im IFC-Manager geöffnet ist.

4.1.4 Preprocessing der Materialien

Nach dem Einlesen beginnt das Preprocessing der Materialien. Das Preprocessing ist ein wichtiger Schritt vor einer Klassifizierung. Es hat Auswirkungen auf die Genauigkeit, Interpretierbarkeit und Robustheit des Gesamtalgorithmus aus. (vgl. Gonzalez and Carlos, 2019) Materialbezeichnungen aus IFC-Dateien können verrauscht und uneinheitlich sein, da es sich um ein Freitextfeld handelt. Die Vorverarbeitung der Daten hilft, die Daten zu säubern und auf das wesentliche reduzieren. (vgl. Chandrasekar and Qian, 2016) Die Vorverarbeitungsstufe besteht normalerweise aus Aufgaben wie Tokenisierung, Entfernung von Stoppwörtern, Umwandlung in Kleinbuchstaben und Stemming. (vgl. Uysal and Gunal, 2014) Für die Materialstrukturierung wird das Preprocessing als erster Schritt aus der Textklassifizierung extrahiert. Somit wirkt sich das Preprocessing auf beide weiteren Schritte (Textklassifizierung und Feinstrukturierung) aus. Außerdem wird das Preprocessing zusätzlich für die Zuweisung der Materialkostengliederung bei der Mengenübernahme als erster Schritt gebraucht. Konkret wird beim Preprocessing folgende Schritte durchgeführt. Als Erstes werden alle Sonderzeichen bis auf „/“ entfernt. Oft befinden sich in der Bezeichnung auch Größen- und Farbangaben, welche irrelevant

für die Materialbeschaffenheit sind. Mithilfe von Regex werden Farben, RGB-Farbcodes (z. B. *60 - 60 - 60*) und Größenangaben (z. B. *400 x 300*) herausgefiltert. Anschließend wird der Text in Worttokens, jeder Token in Kleinbuchstaben umgewandelt und unnötige Leerzeichen entfernt. Aus *„Kunststoff - grau 80-80-80“* wird z. B. *„'kunststoff'“* und aus *„Beton- C30/37 Verputzt“* wird *„'beton', 'c30/37', 'verputzt'“*

4.2 Algorithmen für die Textklassifizierung

Die Textklassifizierung ist nach dem Preprocessing der zweite Schritt der Materialstrukturierung. Hier werden die Materialien, den in Abbildung A.3 aufgelisteten Überkategorien, zugeordnet. Technisch wird dieser Schritt mit der .NET-Bibliothek *ML.NET* implementiert. Das Nuget-Package ist für die Erstellung benutzerdefinierte Modell für maschinelles Lernen. (vgl. Microsoft, 2022*b*) Da die Bibliothek die Anforderungen für die Textklassifizierung gut erfüllen kann, kann die technische Anforderung 4 für diesen Schritt eingehalten werden. Die Bibliothek kann direkt in den ASP.NET-Service integriert werden. In diesem Kapitel wird zuerst der Ablauf einer normalen Textklassifizierung erläutert, die Kriterien der Messbarkeit festgelegt und dann die verschiedenen Algorithmen von *ML.NET* analysiert.

4.2.1 Ablauf einer Textklassifizierung

Die Stufen bei der Klassifikation von Texten sind in Abbildung 4.4 zu sehen. Alle diese Stufen wirken sich auf das Ergebnis der Klassifizierung aus:

Preprocessing

Das in Unterabschnitt 4.1.4 beschriebene Preprocessing findet als erster Schritt der ganzen Materialstrukturierung statt. Ein zusätzliches Preprocessing für die Textklassifizierung gibt es nicht.

Feature Selection

Beim Schritt der Feature Selection werden irrelevante Informationen für die Klassifizierung aus den Ausgangsdaten entfernt. Da es bei der Materialstrukturierung nur die Materialbezeichnung als Feature gibt, muss keine Auswahl aus einem Feature-Set getroffen werden. Es werden lediglich Größen- und Farbangaben aus dem Material-String im Preprocessing entfernt.

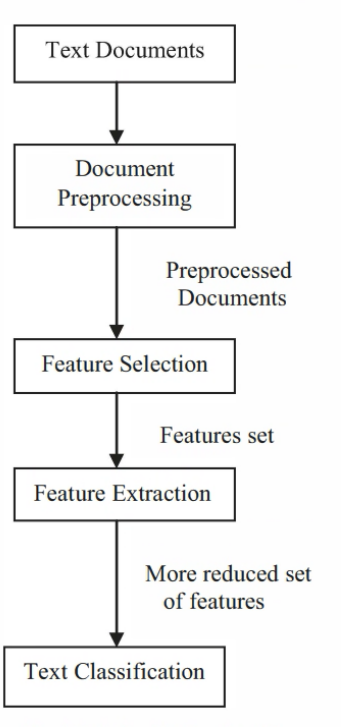

Abbildung 4.4: Stufen der Textklassifizierung (Quelle: Shah and Patel (2016))

Feature Extraction

Definition 3 (Feature extraction)**.** *„Feature extraction addresses the problem of finding the most compact and informative set of features, to improve the efficiency or data storage and processing.“ (Guyon and Elisseeff, 2006)*

Bei der Feature Extraction geht es darum, die rohen Daten in eine numerische Darstellung zu bringen, die möglichst kompakt ist, ohne aber relevanten Informationen zu verlieren. Auch die im Preprocessing entstandenen Worttokens sind noch Zeichenketten, die in eine numerische Darstellung umgewandelt werden müssen.

Classification stages

Nachdem die vorherigen Schritte auf die Daten ausgeführt wurde, kann das Training für die Klassifizierung durchgeführt werden.

4.2.2 Kriterien der Messbarkeit

Für die Textklassifizierung sind folgende Kriterien der Messbarkeit wichtig:

Genauigkeit

Die Genauigkeit bei maschinellem Lernen misst die Wirksamkeit eines Modells. Klassifizierte Daten werden in einen Testdatensatz und einen Trainingsdatensatz geteilt. Mit dem Testdatensatz wird das trainierte Modell getestet. Das Ergebnis der Genauigkeit stellt eine prozentuale Angabe der Übereinstimmung des Testdatensatzes zum trainierten Modell dar. (vgl. Microsoft, 2022*a*)

Interpretierbarkeit

Definition 4 (Interpretierbarkeit)**.** *„Interpretability is the degree to which a human can understand the cause of a decision.“(Miller, 2017)*

Hier geht es darum, die Ergebnisse des Algorithmus nachzuvollziehen zu können. Alleine die Genauigkeit reicht nicht dazu aus, einem Machine-Learning-Algorithmus vertrauen zu können. Ein Modell ist besser interpretierbar als ein anderes Modell, wenn seine Entscheidungen für einen Menschen leichter nachvollziehbar sind als die Entscheidungen des anderen Modells. Die Interpretierbarkeit kann man nicht direkt messen. Sie entsteht aus der Erfahrung über den Algorithmus und die Nachvollziehbarkeit der vorhergesagten Ergebnisse durch Testen. (vgl. Molnar, 2022) Das Endergebnis der Textklassifizierung aus verschiedenen IFC-Dateien, wird fachlich vom Produktmanagement bewertet, da diese das fachliche Wissen haben, um das Ergebnis bewerten zu können. Die Robustheit ist somit auch sehr vom Preprocessing abhängig.

Robustheit

Von Deep-Learning-Algorithmen erwartet man, dass sie robust gegen kleine Störungen in der Eingabe sind. Es wurde allerdings schon festgestellt, dass kleine Störungen teilweise das Ergebnis ändern können. (vgl. Szegedy et al., 2013) Dies kann auch bei anderen Machine Learning Algorithmen auftreten. In Bezug auf die Materialeingabe sollen zum Beispiel verschiedene Satzzeichen keinen Einfluss auf das Ergebnis haben. Die Materialbezeichnung „Holz, Birke“ und „Holz - Birke“ sollen mit dem Algorithmus auf das gleiche Ergebnis führen.

Performance

Aspekte wie Geschwindigkeit und Ressourcenbedarf spielen eine sekundäre Rolle. Wenn es den Anwendungsfluss allerdings sehr beeinträchtigt und verlangsamt, scheidet er als Option aus. Zum Punkt Performance zählt auch die Trainingsdauer des Algorithmus.

Diese kann beim Verglich von verschiedenen Algorithmen helfen.

Konkret für die Textklassifizierung gilt als Kriterien der Messbarkeit die Genauigkeit, und sekundär die Ausführungsgeschwindigkeit und Trainingsdauer. Der Trainingsdatensatz wird aufgeteilt. 80 % werden für das Trainieren und 20 % für die Evaluation genutzt. Die benötigten Werte werden von *ML.NET* geliefert und können für die Auswertung verwendet werden. Bei der Genauigkeit ist vor allem die *MicroAccuracy* entscheidend, da sie den Durchschnitt der Datensätze über alle Klassen hinweg berechnet. Aufgrund des Klassenungleichgewichts gibt die *MacroAccuracy* eine leicht verzerrte Genauigkeit zurück, dass sie nur die durchschnittliche Genauigkeit der einzelnen Klassen berechnet. Für die Genauigkeit wird auch der *LogLoss* in Betracht gezogen. Zusätzlich wird eine Konfusionsmatrix erstellt, welche die Anzahl der vorhergesagten Klassen im Vergleich zu den tatsächlichen Klassen wiedergibt. (vgl. Microsoft, n.d.*c*) Die Trainingsdauer wird mithilfe der `Stopwatch`-Klasse im Code gemessen. Der Service wird dabei lokal auf einem Rechner mit einem Intel Core i7-7700 Prozessor mit einer integrierten Intel HD Graphics 6300 Grafikeinheit im Releasemodus ausgeführt. Zusätzlich wird die Interpretierbarkeit und die Robustheit durch die gesammelten Erfahrungen mit den Algorithmen widergespiegelt, können allerdings nicht wissenschaftlich belegt werden.

4.2.3 ML.NET Multiclass Classification

ML.NET bietet verschiedene `Trainer`-Klassen für das Trainieren von verschiedenen Machine-Learning-Modellen. Diese setzten sich immer aus einem Algorithmus und einem „Task“ zusammen. Der Algorithmus ist die Mathematik, die ausgeführt wird, um ein Modell zu erstellen. Dieser Algorithmus kann für verschiedene Aufgaben angewendet werden. Die Klassifizierung der Materialien fällt unter die Aufgabe der Multiclass Classification, da es mehr als zwei Überkategorien gibt. Je nach Aufgabe hat das vom `Trainer` trainierte Modell, eine andere Ausgabe. (vgl. Microsoft, 2021) Für die Multiclass Classification gibt es in ML.NET verschiedene Vorgehensweisen. Die für den Anwendungsfall interessantesten werden in den folgenden Anschnitten behandelt.

Maximum Entropy Model

Einige Algorithmen benutzen Maximum Entropy Modeling, um ein Modell mit mehreren Klassen zu generieren. Die Entropie kann man als Maß für den Grad der Unsicherheit, beziehungsweise der Informationsdichte einer Information bezeichnen. (Definition 5). Berger et al. (1996) beschreiben die maximale Entropie mit folgendem Prinzip: Die

maximale Entropie entsteht bei einem möglichst einheitlich und gleich-verteilten Modell, das alle bekannten Daten modelliert, allerdings nichts zusätzlich, über noch unbekannte Daten, annimmt. Ein Maximum Entropy Model ist ein stochastisches Modell zur Schätzung der bedingten Wahrscheinlichkeit, dass der Prozess bei einem Kontext x, y ausgibt. Unter allen Modellen ist das Modell mit der größten Entropie zu wählen, das mit den Beschränkungen der Trainingsdaten vereinbar ist. Das Modell ist somit möglichst einheitlich und unvoreingenommen (vgl. Berger et al., 1996).

Definition 5 (Entropie)**.** *„the entropy, H, of a discrete random variable X is a measure of the amount of uncertainty associated with the value of X “ (Shannon (1948) cited in Adriaans (2020))*

Um ein solches Modell zu bekommen, wird eine Optimierungsalgorithmus benötigt. Für jede Nebenbedingung hat das Modell der maximalen Entorpie einen einstellbaren Parameter. Die optimalen Werte dieser Parameter werden durch Maximierung der maximalen Entropie der Trainingsdaten ermittelt. (vgl. Berger et al., 1996)

Die Bibliothek *ML.NET* bietet zwei verschiedene `Trainer` mit zwei verschiedenen Optimierungsmethoden an, welche auf dem Maximum Entropy Modell aufbauen. Der `SdcaMaximumEntropyMulticlassTrainer` basiert auf dem SDCA Optimierungsalgorithmus, welcher von Shalev-Shwartz and Zhang (2013) veröffentlicht wurde. SDCA minimiert die *Maximum Entropy*-Verlustfunktion während des Trainings. Dabei iteriert, der Algorithmus über die Trainingsdatensätze und aktualisiert die Gewichte des Modells. SDCA zeichnet sich vor allem durch seine Performance aus, da er immer nur einzelne Gewichte des Modells anpasst. (vgl. Shalev-Shwartz and Zhang, 2013; Microsoft, n.d.*e*)

Der `LbfgsMaximumEntropyMulticlassTrainer` ist ein weiterer `Trainer`, der auf das Maximum Entropy Modell basiert. Hier wird der Optimierungsalgorithmus limited memory Broyden-Fletcher-Glodfarb-Shanno method (L-BFGS) verwendet. Dieser wurde 1989 von Liu and Nocedal veröffentlicht und gehört zur Familie der quasi-Newton Methoden. Durch den optimierten Speicherverbrauch ist der Optimierungsalgorithmus vor allem bei großer Anzahl von Merkmalen oder einem hochdimensionalen Merkmalsvektor geeignet. (vgl. Microsoft, n.d.*a*)

TextclassifcationTrainer

2022 wurde mit der *ML.NET*-Version 2.0 eine preview Textklassifizierungs-Application Programming Interface (API) veröffentlicht. Dieser Algorithmus benutzt Deep Learning Techniken und arbeitet demnach direkt mit Text als Eingabe. Der Algorithmus basiert auf einem Transformer (Definition 6) welche schon einen internen Encoder besitzt, der

das Vektorisieren der Eingabe durchführt. Da Transformer aufwändig zu trainieren sind, wird ein vortrainiertes NAS-BERT Modell, mit eigenen Trainingsdaten nur noch verfeinert. *Ml.NET* abstrahiert mit dieser Textklassifizierung die Implementierung von *TorchSharp*, was eine .NET Bibliothek für das Trainieren von eigenen neuronalen Netzen ist. (vgl. Quintanilla, 2022)

One Versus All Ansatz

Der `OneVersusAllTrainer` ist eine weitere von *ML.NET* bereitgestellte Vorgehensweise für die Multiclass Classification. Bei diesem wird für jede Klasse ein binärer Klassifizierungsalgorithmus trainiert, welcher die Klasse von allen anderen unterscheidet. Bei Vorhersagen werden dann alle binären Klassifizierer ausgeführt und der mit der höchsten Wertung ausgewählt. Der binäre Klassifizierungsalgorithmus kann frei gewählt werden und liefert einen Klassifizierer, der bei der Vorhersage einen Boolean als Label zurückgibt. (vgl. Microsoft, n.d.*b*) *ML.NET* bietet verschiedene binäre Klassifizierer an. Im Rahmen dieser Arbeit, wird der One-Versus-All Ansatz nur mit dem `SdcaLogisticRegressionBinaryTrainer` analysiert. Dieser ist der genauste binäre Klassifizierer für den Anwendungsfall und wird somit für die Evaluation verwendet. Dieser nutzt den schon beschriebenen Optimierungsalgorithmus SDCA und basiert auf logistischer Regression. (vgl. Microsoft, n.d.*d*)

4.3 Möglichkeiten für die Feinstrukturierung

Die Feinstrukturierung ist nach der Textklassifikation der dritte Schritt der Materialstrukturierung. Hier werden die in eine Überkategorie zugeordneten Materialien weiter hierarchisch strukturiert, um eine feinere und tiefere Baumstruktur zu erreichen. In diesem Kapitel wird das Vorgehen mit einem GPT-Modell von OpenAI und der Implementierung mit *fastText* Encoding und Density Based Clustering analysiert.

4.3.1 Spezifikation und Kriterien der Messbarkeit

Die Verteilung der Materialien auf die Überkategorien ist nicht gleich verteilt. Materialien der Kategorien *Mineralisch* oder *Metall* kommen viel häufiger vor als zum Beispiel *BitumenUndTeer* oder *Gebäudetechnik*. Nicht in jeder IFC-Datei ist eine Einfahrt aus Asphalt oder die Gebäudetechnik im Modell enthalten. Die Verteilung der Materialien ist in Tabelle 4.1 zu sehen. Somit ist auch die Verteilung der Materialien aus einer

IFC-Datei nach dem Schritt der Textklassifizierung in die Überkategorien nicht gleich verteilt.

Eine Feinstrukturierung ist bei zwei Materialien pro Kategorie nicht sinnvoll. Erst bei drei Materialien pro Kategorie wird feiner strukturiert. Die Feinstrukturierung soll keine weiteren, selbst trainierten Klassifizierungsmodelle benötigen. Diese würden zusätzlich zu der Textklassifizierung hohen Wartungsaufwand verursachen, da sie regelmäßig aktualisiert werden müssten, um die Genauigkeit der Klassifizierung beizubehalten bzw. zu verbessern. In den folgenden Kapiteln wird dies einerseits mit dem Benutzen eines fertig trainierten Modells und Unsupervised Learning mit einem selbst trainiertem Worteinbettungs-Modell, welches sehr selten trainiert werden muss, umgangen.

Da es bei diesen beiden Lösungen keine fest definierten Kriterien wie die Genauigkeit liefern, wird die Feinstrukturierung mit einem definierten Testdatensatz evaluiert. Dieser Datensatz umfasst 22 Beispiele zum Testen der beiden Algorithmen. Diese sind in Tabelle A.5 bis Tabelle A.26 zu finden. Die Beispiele wurden in Kooperation mit dem Produktmanagement erstellt und fachlich überprüft. Sie sind auf Basis echter IFC-Dateien entstanden. Eine Tabelle stellt alle Materialien einer IFC-Datei, die in die Überkategorie (in der Überschrift zu sehen) eingeordnet wurden, dar. In der Spalte *Erwartet* sind die Begriffe der erwarteten Unterklasse über eine Nummer zugeordnet. Alle Materialien mit derselben Nummer gehören in eine Unterklasse. Zusätzlich sind für die beiden Algorithmen die Ergebnisse zu sehen. Die Verteilung der Beispiele über die Überkategorien ist aus demselben Grund, wie auch die Verteilung der Materialklassifikationsdaten (siehe Tabelle 4.1), nicht gleich verteilt. Die Ergebnisse der Evaluation sind in Abschnitt 5.2 aufgezeigt.

Kategorie	**Anteil**	**Anzahl**
Metall	25%	119
Glas	4%	17
Holz	9%	43
Kunststoff	8%	39
BitumenUndTeer	1%	3
Mineralisch	26%	127
Verbundbauteile	5%	22
Dämmungen	8%	39
GebäudeTechnik	1%	6
Sonstiges	14%	70
Gesamt	100%	485

Tabelle 4.1: Verteilung der Materialklassifikationsdaten

4.3.2 Generative Pretrained Transformer (GPT) Modell von OpenAI

OpenAI ist ein Unternehmen für KI-Forschung und -Einsatz. Sie bieten verschiedene, fertig trainierte KI-Modelle über eine API an. Neben Speech-ToText und einem Bildgenerierungsmodell gibt es das Sprachverarbeitungsmodell GPT. (vgl. OpenAI, n.d.*a*) Die Nutzung eines fertig trainierten Modells hat einige Vorteile. Vor allem werden so die Problemstellung 3 und Problemstellung 4 automatisch gelöst. OpenAI benutzen ihr eigenen ausgereiften Textrepräsentationsmodelle. Somit wird auch die Bedeutung von Worten bei den kurzen Materialangaben bei der Vektorisierung beibehalten. Außerdem kann das Modell durch die Masse an Trainingsdaten aus Büchern, Artikel und Webseiten auch mit vielen Fachbegriffen umgehen. Zusätzlich spart man sich die Wartung eines selbst trainierten Modells. Das Etikettieren von Daten ist sehr Zeit und auch Ressourcen-aufwändig, da es von einer Person gemacht werden muss, die passende fachliche Kenntnisse besitzt.

Der Begriff GPT steht für eine Reihe von vor trainierten Sprachmodellen, die von OpenAI entwickelt wurden. Diese sind populäre Transformer für die Generierung von natürlicher Sprache. (vgl. Zhu and Luo, 2022)

Definition 6 (Transformer)**.** *„Transformers are a type of artificial neural network architecture that is used to solve the problem of transduction or transformation of input sequences into output sequences in deep learning applications. “ (Rogel-Salazar, 2022)*

GPT ist also ein Modell, das auf einem großen Datensatz an textuellen Informationen trainiert wurde und kann zur Bewältigung spezifischer sprachbezogener Aufgaben eingesetzt werden. Im Vergleich zu Modellen wie zum Beispiel BERT, welche natürlicher Sprache verstehen können, kann GPT natürliche Sprache generieren. Der Algorithmus liefert basierend auf allen eingegebenen Tokens neue Tokens, welche dann die Antwort darstellen. (vgl. Zhu and Luo, 2022)

OpenAI hat verschiedene Versionen des GPT Algorithmus. GPT 1 wurde 2018 veröffentlicht. Darauf folgte GPT 2 2019. Beide Modelle wurden in zwei Schritten trainiert. Zuerst wurde ein Model mithilfe von Unsupervised Learning mit einer sehr großen Datenmenge vortrainiert und konnte dann für bestimmte Aufgaben mit dem Training von überwachten Datensätzen verfeinert werden. (vgl. Radford, 2018) GPT 3 wurde dann nur noch in einem Schritt trainiert und verzichtet auf die kontextbezogene Verfeinern des Modells. (vgl. Zhu and Luo, 2022) Stattdessen nutzt das Modell „Meta-Learning“. Es entwickelt somit beim Training ein breites Spektrum an Mustererkennungsfähigkeiten und weiteren Fertigkeiten, die sich beim Ausführen des Modells schnell an die gewünschte Aufgabe anpassen. Durch die Skalierung des Modells auf 175 Billionen Parameter wurden

ähnliche Ergebnisse wie bei damaligen modernster fein abgestimmter Systeme erzielt. (vgl. Brown et al., 2020)

Die GPT-Modelle 2 und 3 sind nicht darauf trainiert, Benutzeranweisungen zu befolgen. Dafür wurde 2022 *InstructGPT* auf der Basis des GPT 3 Modell trainiert. Mit Supervised Learning und Reinfocement Learning wurde das Modell verfeinert, um hilfreichere Ergebnisse bei Benutzeranweisungen zu bekommen. Zusätzlich wurde eine Reduktion von toxischen Antworten erzielt. (vgl. Ouyang et al., 2022)

Das für die Material-Feinstrukturierung verwendete Modell *ChatGPT* ist ein Zwillingsmodell von *InstructGPT* und ist eine Feinabstimmung eines Modells der GPT-3.5-Serie. (vgl. OpenAI, 2022) Das Modell wurde Ende 2022 veröffentlicht und ist über eine öffentliche API erreichbar und kann mithilfe des Python-Package *openai* leicht genutzt werden. Als Parameter wird die *temperature* mit dem Wert 0 angegeben. Das bedeutet, dass das Ergebnis möglichst deterministisch ist. (vgl. OpenAI, n.d.*b*) Die Nutzung kostet 0.002 $ pro 1000 Tokens. (vgl. OpenAI, n.d.*c*) Ein Request kostet also je nach Eingabe und Antwortlänge bei 150 bis 450 Tokens circa 0,0003 $ bis 0,0009 $.

4.3.3 fastText mit Density-Based Spatial Clustering of Applications with Noise (DBSCAN)

In diesem Ansatz werden mithilfe von Clustering, Materialien weiter strukturiert. Durch das Nutzen von Unsupervised Learning müssen so keine weiteren Klassifizierungsmodelle trainiert und verwaltet werden. Um Problemstellung 3 zu lösen, wird das Vorgehen, wie es auch Bie (2019) vorgeschlagen hat, angewandt. Ein Textrepräsentationsmodell wird mit anderen Texten trainiert und mit diesem Modell die Vektorisierung auf die Materialbezeichnungen angewandt. Die „ORCA Software GmbH“ entwickelt neben der ORCA AVA das Portal ADE. Dieses hat über einer Millionen Ausschreibungstexte von über 800 verschiedenen Herstellern. Diese Texte eignen sich optimal für das Trainieren des Worteinbettung-Modells. Sie enthalten viele Materialnamen und weitere Fachbegriffe der Baubranche, welche essenziell für Materialstrukturierung sind. Somit ist zusätzlich Problemstellung 4 gelöst. Auch Nooralahzadeh et al. (2018) kommt auf das Ergebnis, dass sich Domänen-Spezifische Worteinbettungen auch schon mit limitierter Eingabedaten nützlich ist. Die Ausschreibungstexte werden mit einem schon existierendem Preprocessing verarbeitet und liefern am Ende ca. 360.000 Sätze mit über 300.000 verschiedene Wörtern. Im Preprocessing werden verschiedene Zeichenketten aus den Texten mithilfe von Regex herausgefiltert. Dazu gehören Uniform Resource Locator (URL)s, verschieden Normen wie DIN und Attribut-Listen wie zum Beispiel *Nettogewicht: 0,196*

kg. Zusätzlich werden unnötige Absätze entfernt. Auch wenn Ausschreibungstexte oft keine kompletten Sätze beinhalten, werden so viele nicht relevanten Daten entfernt.

Als Textrepräsentation und Wort-Einbettungs-Algorithmus bietet sich *fastText* an. *fastText* wurde 2016 von Facebook veröffentlicht (vgl. Bojanowski et al., 2016). Außerdem wurde die dazu getätigte Forschung mit Bojanowski et al. (2017) und Joulin et al. (2016) veröffentlicht.

Das Modell basiert auf dem Wort-Einbettungs-Algorithmus *Word2Vec* mit *Continuous Skip-Gram* und *Continuous Bag Of Words (CBOW)* (vgl. Bojanowski et al., 2017). Das Modell nutzt ein neuronales Netz, bei dem am Ende die generierten Gewichte als Vektor für ein Wort stehen. Die Trainingsdaten für das neuronale Netz entstehen durch ein selbst gestelltes Problem. Mit CBOW versucht man mit nahegelegenen Wörtern ein Wort hervorzusagen. Die nahegelegenen Wörter sind beim Trainieren dann die Features und das hervorzusagende Wort das Label. Bei Skip-Gram versucht man entgegengesetzt aus einem Wort den Kontext, also die naheliegenden Wörter hervorzusagen. So kann beim Iterieren über den Trainingstext das Modell immer weiter trainiert werden. In Abbildung 4.5 sieht man ein CBOW Beispiel, in dem die Kontextwörter als Input Layer und das gesuchte Wort als Ergebnis zur Ermittlung des Verlustes genutzt werden. Die nach dem Trainieren entstandenen Gewichte $W1_{n\times k}$ sind dann die Repräsentation für das Wort *catches*. *fastText* erweitert diese Vorgehensweise und nutzt Teilwortinformationen,

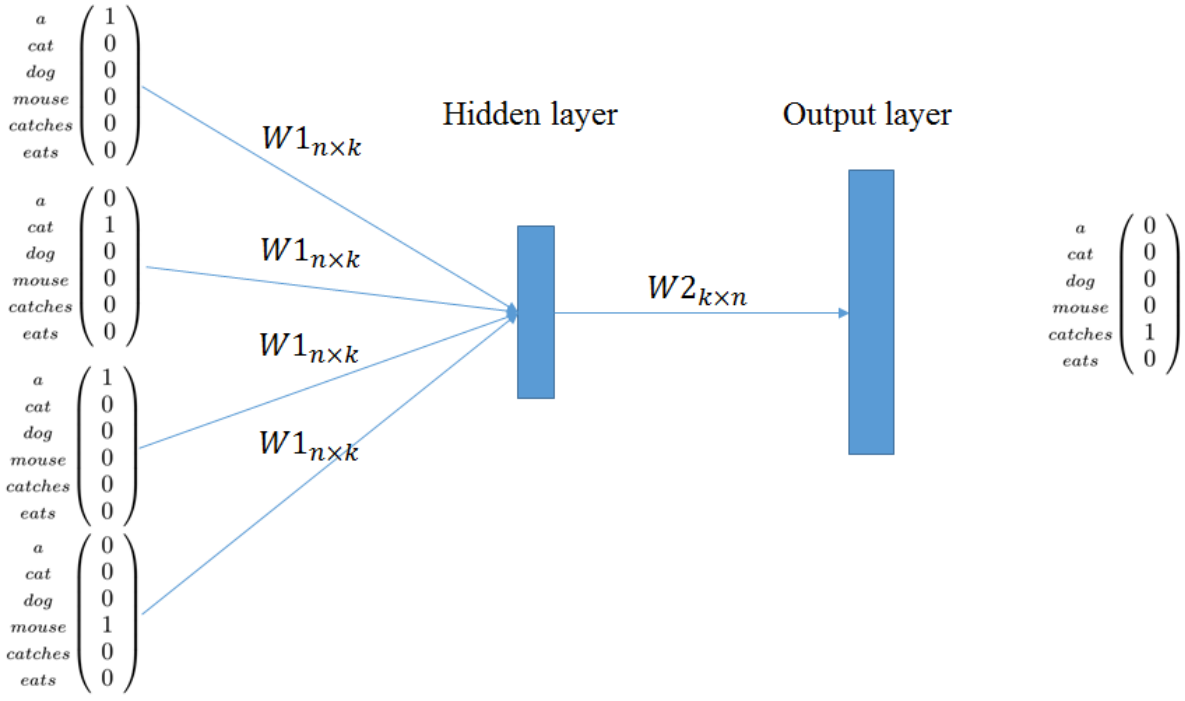

Abbildung 4.5: Beispiel des CBOW-Modells. (Quelle: Ferrone and Zanzotto (2019))

um ein Wort als Vektor darzustellen. Wörter werden in N-Grams dargestellt. (vgl. Bojanowski et al., 2017) Die Repräsentation für das Wort *Estrich* mit n = 3 ist zum Beispiel *<Es,est,str,tri,ric,ich,ch>*, wobei die Zeichen < und > als Begrenzungszeichen hinzugefügt werden, um die N-Gramms eines Wortes vom Wort selbst zu unterscheiden. Wäre also das Wort *ich* im Vokabular, wird es als *<ich>* dargestellt. Das neuronale Netz wird dann mit der Liste der N-Gramms inklusive dem kompletten Wort trainiert. Somit ermöglicht das Modell die gemeinsame Nutzung der Teilwortinformationen für alle Wörter (vgl. Bojanowski et al., 2017). Zusätzlich nutzt *fastText* eine hierarchische Softmax Verlustfunktion, um die Berechnung von unausgewogenen Verteilungen zu beschleunigen (vgl. Bojanowski et al., 2016).

fastText hat für den Anwendungsfall folgende Vorteile:

- *fastText* kann mit Wörtern außerhalb des Vokabulars umgehen. Bei unbekannten Wörtern werden die Vektoren der einzelnen Char-Ngramms summiert. Es muss allerdings mindestens eines der Char-Ngrams in den Trainingsdaten vorhanden sein. (vgl. Gensim Documentation, n.d.; Le and Mikolov, 2014) Da sich bei diesem Konzept der Feinstrukturierung das Vokabular bei Ausführung vom Trainingsvokabular unterscheidet, ist das Verarbeiten von unbekannten Wörtern essenziell.

- *fastText* liefert Vektordarstellungen mit fester Länge, welche für das Clustering mit zum Beispiel DBSCAN nötig ist. (vgl. Le and Mikolov, 2014)

- *fastText* liefert bessere Ergebnisse bei syntaktischen Aufgaben als zum Beispiel *Word2Vec* und *Bag of Words* (vgl. Gensim, n.d.; Le and Mikolov, 2014)

- *fastText* hat eine schnellere Trainingszeit als vergleichbar genaue Deep Learning Algorithmen (vgl. Bojanowski et al., 2016)

Mit dem fertige trainierten *fastText* Modell können dann Wörter in Vektoren umgewandelt werden. Bei der Vektorisierung von Materialien, die aus mehreren Wörtern bestehen, werden die Vektoren der einzelnen Wörter aufaddiert. Das ist dieselbe Vorgehensweise, wie *fastText* bei neuen Worten, die nicht im Vokabular vorkommen, vorgeht (vgl. Gensim Documentation, n.d.).

Wenn die Materialbezeichnungen vektorisiert wurden, können sie geclusterd werden. Aus einer großen Auswahl an Cluster-Algorithmen bietet sich DBSCAN an. „The DBSCAN algorithm views clusters as areas of high density separated by areas of low density.“ (scikit-learn developers, n.d.) Der Algorithmus wurde 1996 von Ester et al.

vorgestellt und veröffentlicht. Ziel war es einen Algorithmus zu entwickeln, bei dem man wenig Fachwissen für die Bestimmung der Parameter braucht, Cluster mit beliebiger Form bekommen kann und eine gute Effizienz bei großen Datenbanken besitzt.

DBSCAN müssen nur die zwei Parameter *min_samples* und *eps* übergeben werden. Als erster Schritt werden alle Punkte, die inklusive sich selbst mindestens *min_samples* an Nachbarn innerhalb des Abstands von *eps* haben, als Kernpunkte definiert. Alle anderen Punkte werden erstmals als Rauschen gekennzeichnet. Als Nächstes werden alle Kernpunkte, die inherhalb des Radius *eps* beieinander liegen als ein Cluster definiert. Zum Schluss werden nochmal alle Rauschpunkte überprüft, ob sie nicht doch innerhalb des Radius eines Kernpunktes in einem Cluster liegen. (vgl. scikit-learn developers, n.d.; Ester et al., 1996) Die Anzahl der Cluster ist also abhängig von den Daten (und den Parametern) und muss nicht vorgegeben werden. DBSCAN hat also für den Anwendungsfall folgende Vorteile:

- DBSCAN liefert eine passende Anzahl von Clustern, abhängig von den Materialbezeichnungen. Dies ist wichtig, da die Anzahl der in eine Überkategorie zugewiesene Materialien und somit auch die Anzahl der potenziellen Clustern immer unterschiedlich ist. Das Ergebnis des Clustering wird auch direkt dem Benutzer der ORCA AVA präsentiert. Somit ist es auch nicht möglich, mit einem anderen Clustering-Algorithmus über die Anzahl von Clustern zu iterieren und das fachlich beste auszuwählen.
- Es müssen keine Trainingsdatensätze oder Modelle verwaltet werden.
- Der Algorithmus setzt die mitgegebene Bedeutung des Wortes bei der Wort-Einbettung mit *fastText* um.

Am Ende liefert DBSCAN zu jedem übergebenem Material eine Zahl, die das Cluster repräsentiert. Rauschpunkte werden mit -1 zurückgegeben. Diese werden dann nicht weiter strukturiert und bleiben hierarchisch direkt unter ihrer zugewiesenen Überkategorie. Dieses Format kann für die Evaluationsbeispiele (Tabelle A.5 - Tabelle A.26) direkt genutzt werden. Bei diesem Ergebnis fehlen für die endgültige Materialstrukturierung noch die Begriffe der Gliederungspunkte für die entstandenen Cluster. Hierfür wird der größte gemeinsame Nenner der Zeichenketten genutzt.

5 Gegenüberstellung der möglichen Konzepte

In diesem Kapitel werden die in Kapitel 4 vorgestellten Algorithmen verglichen. Dies wird gesondert für die Textklassifizierung und die Feinstrukturierung durchgeführt. Es wird jeweils das Ergebnis ausgewertet und eine Auswahl eines Algorithmus durchgeführt.

5.1 Vergleich der Textklassifizierung

Für die Textklassifizierung wird der beste Algorithmus der *ML.NET*-Bibliothek gesucht. Zur Auswahl stehen das *Maximum Entropy Model* mit SDCA oder L-BFGS als Optimierungsalgorithmus, die preview Textklassifizierungsschnittstelle basierend auf einem NAS-BERT Transformer und der One-Versus-All Ansatz mit einem binären Klassifizierer basierend auf logistischer Regression mit dem SDCA Optimierungsalgorithmus.

5.1.1 Auswertung

Bei der Textklassifizierung werden die Algorithmen nach den in Unterabschnitt 4.2.2 erläuterten Kriterien der Messbarkeit ausgewertet. Die Ergebnisse sind in Tabelle 5.1 zu sehen. Zusätzlich befinden sich in Tabelle A.1, A.2, A.3 und A.4 die Konfusionsmatrix für jeden Algorithmus. Da nur 500 Datensätze zum Trainieren zur Verfügung stehen, konnten nur 20 % und somit 94 Testdatensätze definiert werden. Da diese von *ML.NET* zufällig ausgewählt werden, kann es zu Variationen der Ergebnisse kommen. Die in dieser Arbeit verwendeten Messdaten repräsentieren eine durchschnittliche Auswertung der Algorithmen.

Algorithmus	**MicroAccuracy**	**MacroAccuracy**	**LogLoss**	**TrainingTime**
SdcaMaximumEntropy	0,882	0,910	0,477	0,245sec
LbfgsMaximumEntropy	0,670	0,591	1,131	0,243sec
TextClassification	0,479	0,292	5,994	20,229sec
OneVersusAll SdcaLogisticRegression	0,872	0,894	0,477	4,219sec

Tabelle 5.1: Auswertung der Textklassifizierungsalgorithmen

Die Klassifizierungsalgorithmen liefern verschiedene Ergebnisse. Bei der Betrachtung der Genauigkeit schneidet *SdcaMaximumEntropy* mit einer Genauigkeit von 88,2 % am besten ab, dicht verfolgt von *OneVersusAll* mit 87,2 %. *LbfsgMaximumEntropy* und die *TextClassification* haben dagegen nur eine Genauigkeit von 67 % bzw. 48 %. In den Konfusionsmatrizen dieser beiden erkennt man, dass vor allem die Klassen *Mineralisch* und *Metall* mit einer schlechten Genauigkeit von 43 % bzw. 35 % abschneiden. Mineralische Materialien wurden hier zwar meistens (96 %/87 %) richtig zugeordnet. Materialien vieler anderer Klassen wurden aber auch in diese beiden Klassen bei der Vorhersage zugewiesen. Bei *SdcaMaximumEntropy* und *OneVersusAll* ist das ähnlich zu beobachten. Mineralische Materialien werden bei beiden Modellen zu 92 % richtig klassifiziert. Hier ist die Genauigkeit aller mineralisch zugeordneten Materialien bei 76%. Der LogLoss ist bei diesen beiden Modellen auch mit 0,477 deutlich niedriger als bei den anderen Algorithmen.

Die Maximum Entropy Modelle scheiden bei der Trainingsdauer am besten ab. Mit ca. 0,24 Sekunden ist die Trainingszeit bei beiden Modellen zu vernachlässigen und kann theoretisch sogar nach jedem neu klassifizierten Datensatz direkt durchgeführt werden. Da der *OneVersusAll* Algorithmus mehrere binäre Modelle trainieren muss, braucht er mit 4,2 Sekunden deutlich länger. Das *TextClassification* Modell braucht ganze 20 Sekunden, um die 406 Datensätze zu trainieren.

5.1.2 Auswahl eines Algorithmus

Die Wahl des Textklassifizierungsalgorithmus fällt eindeutig auf *SdcaMaximumEntropy*. Mit einer Genauigkeit von 88,2 % wurde ein nutzbares Ergebnis erzielt. Zusätzlich ist es der Algorithmus mit der kürzesten Trainingsdauer. Auch wenn der *OneVersusAll* Ansatz auf eine ähnliche Genauigkeit kommt, dauert das Training deutlich länger und das gespeicherte Modell braucht mehr Speicher, als das gespeicherte *SdcaMaximumEntropy* Modell. Zusätzlich wurde das *SdcaMaximumEntropy* Modell dem Projektmanagement vorgestellt und fachlich evaluiert. Das Ergebnis wurde als fachlich brauchbar eingestuft und kann somit für die Textklassifizierung genutzt und integriert werden.

Um die Anzahl der Trainingsdaten besser einschätzen zu können, wird in Abbildung 5.1 der Genauigkeitsverlauf für die jeweilige Anzahl der Trainingsdaten gezeigt. Man sieht eine abflachende Kurve, die andeutet, dass der Anstieg der Genauigkeit bei noch größerer Trainingsdatenanzahl immer kleiner wird. Mit mehr Trainingsdaten wird allerdings auch die Anzahl der Testdaten größer und somit auch die Genauigkeit konstanter. Es wäre somit langfristig noch sinnvoll, die Trainingsdaten zu erweitern.

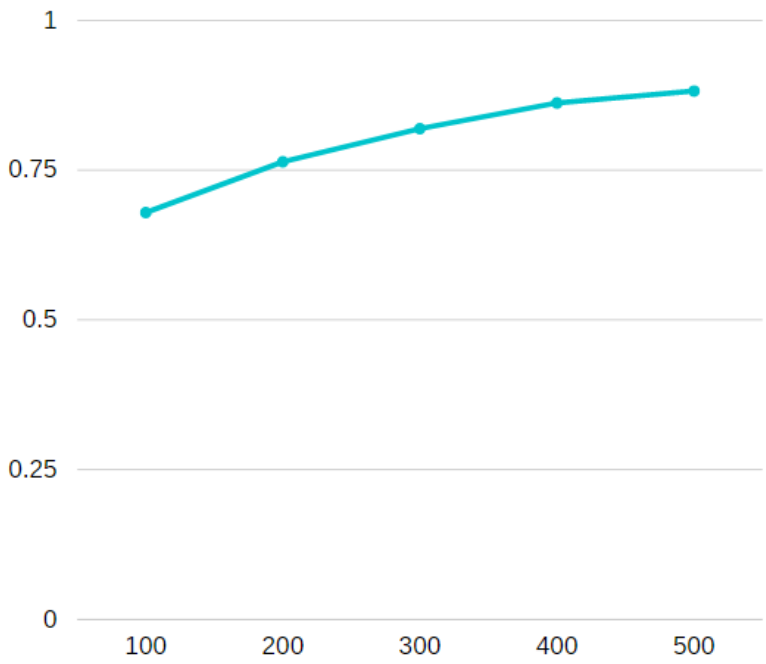

Abbildung 5.1: Genauigkeit des SdcaMaximumEntropy-Modells für die jeweilige Trainingsdaten-Anzahl. (Durchschnittswerte von 100 Trainingsdurchläufen bei einem Testsplit von 0.2)

5.2 Vergleich der Feinstrukturierung

Bei der Feinstrukturierung wird zwischen dem fertig trainierten GPT-Modell von OpenAi und einem selbst implementieren Vorgehensweise mit *fastText* und DBSCAN-Clustering verglichen.

5.2.1 Auswertung

Die Algorithmen für die Feinstrukturierung werden zuerst nach den Kriterien der Messbarkeit aus Unterabschnitt 4.3.1 ausgewertet. Das Ergebnis ist in Tabelle A.5 bis Tabelle A.26 mit eingetragen. -1 bedeutet, dass das Ergebnis nicht nutzbar ist, da zum Beispiel die Materialbezeichnung vom Algorithmus verändert wurde. Zusätzlich ist in Tabelle 5.2 eine akkumulierte Auswertung zu sehen, bei der die Ergebnisse in folgende Klassen zusammengefasst wurden. *Richtig* heißt, dass das Ergebnis mit dem erwarteten Ergebnis übereinstimmt. *Teilweise Richtig* bedeutet, dass manche Materialien zwar nicht zugewiesen wurde, aber es keine fachlich falsche Zuweisung enthält. Dieses ist laut dem Produktmanagement als ausreichendes Ergebnis für die Feinstrukturierung zu sehen.

Bei *Falsch* wurde ein oder mehrere Materialien falsch zugewiesen, oder das Ergebnis war nicht für die Weiterverarbeitung nutzbar.

	fastText & DBSCAN	**OpenAI**
Richtig	9	5
Teilweise Richtig	6	10
Falsch	7	7

Tabelle 5.2: Auswertung der Feinstrukturierung in *Richtig*, *Teilweise Richtig*, und *Falsch*

Vorteile von *fastText & DBSCAN*:

- Besseres Ergebnis bei der Auswertung der Evalutaionsbesipiele (siehe Tabelle 5.2)
- deterministischer Algorithmus liefert für gleiche Eingabe immer das gleiche Ergebnis
- keine zusätzlichen Kosten
- Gute Interpretierbarkeit des Algorithmus

Nachteile von *fastText & DBSCAN*:

- Erhöhter Aufwand durch das Pflegen und Verbessern des selbst trainierten *fastText*-Modells
- Clustert teilweise nach irrelevanten Worten. (z.B.: matt, verputzt)

Vorteile von *ChatGPT*:

- Kein Wartungsaufwand von selbst trainierten Modellen.
- Liefert fachlich meistens ein fachlich richtiges Ergebnisse.

Nachteile von *ChatGPT*:

- Verändert Materialbezeichnungen, was das Ergebnis für als Kostengliederung nicht brauchbar macht. Aus *Stahl matt* wird zum Beispiel *1.1 Stahl* und *1.1.1 matt*
- Die Ausgabe ist trotz *Temperature* von 0 nicht deterministisch. Das senkt in Kombination mit der Veränderung von Begriffen die Interpretierbarkeit des Algorithmus.
- Die Form der Ausgabe als Zeichenkette und mögliche Variationen in der Struktur der Ausgabe kann zu Fehlern beim Abbilden in die Objektstruktur führen.
- Zusätzlicher Kostenaufwand von 0.002 $ pro 1000 Tokens

5.2.2 Auswahl eines Algorithmus

Für die Feinstrukturierung kommt nur *fastText & DBSCAN* als einzige Option infrage. Das fachliche Ergebnis der jeweiligen Strukturierung lässt beide Optionen für die Feinstrukturierung zu. *fastText & DBSCAN* scheiden bei den Evaluationsbeispielen aber auch schon besser ab. Die beiden Algorithmen unterscheiden sich vor allem in der Interpretierbarkeit (Definition 4). Die genannten Nachteile von *ChatGPT* führen schnell zu fehlender Interpretierbarkeit und somit zu Misstrauen gegenüber der Programmerweiterung. Vor allem die Kombination der einzelnen Nachteile lässt manche Ergebnisse willkürlich erscheinen. Zusätzlich können mit *ChatGPT* oft kein Ergebnis zur Verfügung gestellt werden, da nach der Veränderung von Materialbezeichnungen die ursprünglichen Materialien nicht mehr nachvollzogen werden können. *fastText & DBSCAN* schneiden in der Interpretierbarkeit gut ab. Das entsteht durch deterministische Ergebnisse und nachvollziehbares Clustering. Das Zusammenfassen von mehreren Materialien in ein Cluster kann immer, auch bei einem fachlich falschen Ergebnis, nachvollzogen und eine Logik hinter der Strukturierung gefunden werden. Durch die bessere Interpretierbarkeit wird *fastText & DBSCAN* als Algorithmus für die Feinstrukturierung festgelegt.

6 Praktische Umsetzung

In diesem Kapitel wird die Umsetzung der ausgewählten Algorithmen und Bibliotheken beschrieben. Zuerst wird die Implementierung des Services und der Python-Interop gezeigt. Danach geht es um die konkrete Implementierung der Materialstrukturierung.

6.1 Implementierung des ASP.NET Services

Die Realisierung als ASP.NET Service ist eine Anforderung der „ORCA Software GmbH“. Für das Erstellen eines neuen Services gibt es ein fertiges Projekttemplate, welches nur umbenannt werden muss. Die Vorlage liefert eine einheitliche Projektstruktur und zeigt den Aufbau des Services anhand der Implementierung eines Beispiels. Die neu genannte *MaterialStructurizationApi* hat zwei verschiedene REST-Controller. Diese teilen sich, wie im Anwendungsfalldiagramm (Abbildung 4.1) zu sehen, in die Schnittstellen für die ORCA AVA Benutzer und die ORCA internen Schnittstellen auf. In den Controllern werden die REST-Schnittstellen-Methoden definiert. Dazu zählt die Art der Anfragemethoden, die Request-URL oder auch die möglichen Antwort-StatusCodes. Service interne Logik wird im `MaterialService` organisiert. Hier werden die Data Transfer Objects (DTOs) in Entitäten umgewandelt und die Aufrufe auf die entsprechenden weiteren themenspezifischen `Services` oder Datenzugriff-Repositories weitergeleitet. Am Ende werden Rückgabewerte wieder in entsprechende DTOs abgebildet und an den Controller zurückgegeben. Ein Beispiel ist in Codeauflistung A.1 zu sehen. Die Methode ist für die Materialstrukturierung zuständig. Sie bekommt die Liste von Manualbezeichnungen und eine `bool`, welcher bestimmt, ob die Feingliederung durchgeführt werden soll, übergeben. Nach der Parameterprüfung werden Duplikate aus der Materialliste entfernt und danach in Zeile 8 über das `MaterialRepository` neue Materialien dem Trainingsdatensatz für die Klassifizierung hinzugefügt. Danach wird der `Material-StructurizerService` aufgerufen, der sich dann um die Logik der Strukturierung kümmert.

Repositories kapseln den Datenzugriff über Interfaces. So ist die Logikimplementierung in den Services unabhängig von der Implementierung des Datenbankzugriffs. Der

Datenbankzugriff wird in den Repositories mit der Object-Relation-Mapper Bibliothek *EntityFramework* implementiert. Es wird der Model-First Ansatz verwendet, bei dem zuerst die Objektstruktur im C#-Code definiert wird und daraus automatisiert die Datenbank generiert wird.

6.2 Python-Interop

Für die Implementierung einiger Komponenten wird Python als Programmiersprache benötigt. Der Webservice wird allerdings mit ASP.NET implementiert. Um die Kommunikation zwischen .NET und Python zu vereinfachen, wird das Nuget-Packet `pythonnet` verwendet. Die Bibliothek vereinfacht es, Python-Code aus dem C#-Code auszuführen und verschiedene Python-Variablen auszulesen oder diesen Werte zuzuweisen. Um den Python-Interop nutzen zu können, muss eine lauffähige Python-Umgebung in der Ausführungsumgebung installiert sein. Der Python-Interop ist in mit dem Interface `IKiExecuter` gekapselt und lässt so eine eventuelle C# Ablösung der Python-Komponenten in der Zukunft einfach integrieren. In Codeauflistung 6.1 ist der Python-Code Aufruf für das Preprocessing zu sehen. Nachdem die Python-Engine initialisiert wird, kann der Python-Variable ein Wert zugewiesen werden. Dann wird das Skript *preprocess.py* (Codeauflistung A.3) über den Namen aufgerufen und danach die Python-Variable `material_preprocessed`, in welcher am Ende des Python-Skripts das Ergebnis steht, wieder ausgelesen.

```
1  PythonEngine.Initialize();
2
3  using (Py.GIL())
4  {
5      using (PyModule scope = Py.CreateScope())
6      {
7          scope.Set("material_raw", materials);
8          scope.Exec(File.ReadAllText(GetPythonScript("preprocess")));
9          string materialPreprocessed = scope.Get("material_preprocessed"
               ).As<string>();
10     }
11 }
```

Codeauflistung 6.1: Python-Interopt für das Preprocessing

Zusätzlich löst *pythonnet* das Problem, dass das Pythonskript zur Feinstrukturierung nicht immer wieder das *fastText*-Modell neu in den Speicher laden muss. Durch die Möglichkeit Python-Variablen zuzuweisen und auszulesen, ist es auch möglich das

fastText-Modell initial beim Starten des Services in den Speicher zu laden. Das macht das Ausführen der Feinstrukturierung sehr viel performanter und erst produktiv einsetzbar.

Für die Entwicklung der Pythonskripte wird die Logik immer in eine Methode ausgelagert. Mit der Zeile `if __name__ == "__main__":` wird der darauf folgende Code beim initialen Aufrufen des Skriptes ausgeführt. Mit einem Try-Except-Block wird überprüft, ob durch *pythonnet* die Eingabevariable schon initialisiert wurde. Ansonsten kann beim Debuggen ein Wert über die Kommandozeile eingetragen werden. Somit kann für alle Konstellationen immer nur ein Skript verwendet werden. Das ganze Skript inklusive der definierten Methoden können dann mit *pythonnet* im C#-Code und aber auch autark im Debug-Modus ausgeführt werden. (Beispiel: Codeauflistung A.3)

6.3 Implementierung der Materialstrukturierung

Die Implementierung der Materialstrukturierung teilt sich ähnlich wie in Kapitel 4 auf. Zuerst geht es um das Erstellen einer Datengrundlage, dann um die Implementierung des Preprocessings. Anschließend wird das Textklassifizierungsmodell vorgestellt. Für die Feinstrukturierung wird am Ende noch die Implementierung für *fastText* und DBSCAN erläutert.

6.3.1 Erstellen einer Datengrundlage

Die Datengrundlage entstand durch das Extrahieren der Materialangaben (wie in Unterabschnitt 4.1.3 beschrieben) aus verschiedenen IFC-Dateien. Hierzu standen über 500 verschiedene Dateien zur Verfügung. Die daraus entstandenen Materialbezeichnungen wurden über eine Hypertext Transfer Protocol (HTTP)-PUT Anfrage in einem SQL-Server mit dem in Abbildung 4.2 abgebildetem Schema persistiert. Die Liste dieser Materialien wurden anschließend manuell gefiltert. In vielen IFC-Dateien werden die Möglichkeiten der Materialangabe noch nicht gut genutzt. Deshalb waren viele Materialangaben nicht aussagekräftig, um sie als Trainingsdaten für die Textklassifizierung zu nutzten. Am Ende standen circa 500 unterschiedliche Materialbezeichnungen zur Verfügung. Um die Daten anschließend zu klassifizieren, wurde ein Klassifizierungs-Service mit Oberfläche implementiert (siehe Abbildung A.11). Dieser stand im internen Firmennetzwerk zur Verfügung, sodass ausgewählte Mitarbeiter die Materialien klassifizieren konnten. Die dafür benötigten Methoden standen über den `InhouseMaterialController` der *MaterialStructurizationApi*, welcher die internen ORCA-Schnittstellen bietet, zur Verfügung. Somit wurden über 480 klassifizierte Datensätze geschaffen. Die

Verteilung der Klassifizierung ist in Abbildung A.7 zu sehen.

6.3.2 Implementierung des Preprocessings

Das Preprocessing für die Textklassifizierung wurde in Python implementiert. Das Vorgehen wurde schon in Unterabschnitt 4.1.4 erläutert. Die Implementierung des Pythonskripts ist in Codeauflistung A.2 zu sehen. Das Preprocessing basiert größtenteils auf der Textverarbeitung mit Regex. Mit dem Regex `[A-Za-z0-9üäöÜÄÖßóåéèÉÈÓ/]` werden alle Sonderzeichen bis auf „/“ aus dem String entfernt. Bei der Maßangabe mussten aufgrund der unterschiedlichen Verarbeitung bei gleicher Eingabe des Python-Package `re` bei `re.findall(...)` `re.sub(...)` mehrere Regex definiert werden. Zuerst werden dreidimensionale Maße im Materialstring gesucht. Wenn keine vorhanden sind, werden zweidimensionale Maße entfernt. Ansonsten wird mit einem zusätzlichen Regex die dreidimensionalen Maßangaben entfernt. Am Ende wird eine Liste von Strings aus dem Materialstring gefiltert und überschüssige Leerzeichen mit `strip()` entfernt.

Wie in Abbildung 4.2 zu sehen ist, werden die vorverarbeiteten Materialien in der Datenbank persistiert. Immer wenn ein neues Material in die Datenbank geschrieben wird, wird das Preprocessing gestartet. Das bietet die Möglichkeit direkt nach dem Klassifizieren eines Materials, das Textklassifizierungsmodell ohne vorheriges Preprocessing aller Datensätze neu trainieren zu können. Dadurch verringert sich die Ausführungszeit des Trainingsprozesses und es kann direkt auf das aktualisierte Modell zugegriffen werden.

6.3.3 Training des Textklassifizierungsmodells

ML.NET bietet einem für jedes Machine-Learning-Model eine ähnliche Codestruktur. Diese ist in Abbildung A.12 aufgezeigt. Parallel dazu ist in Codeauflistung 6.2 ein leicht vereinfachter Codeausschnitt für das Trainieren des Materialklassifizierungsmodells zu sehen. Im Trainingsprozess wird nach dem Laden der Trainingsdaten in den Trainingskontext die Pipeline definiert. Mit der `Append()`-Methode können verschiedene Schritte der Pipeline hinzugefügt werden. Im ersten Schritt werden die Texte normalisiert und mit Bag-of-words und N-Grams in Vektoren umgewandelt. Als Nächstes wird der `SdcaMaximumEntropy` als Klassifizierungsalgorithmus hinzugefügt. Mit `MapKeyToValue()` werden die Schlüsseltypen in ihre ursprünglichen Werte zurück umgewandelt. Mit der `Fit()`-Methode wird die Trainingspipeline ausgeführt und ein Modell erzeugt. Mit `Evaluate` kann das Modell dann analysiert und bewertet werden. Die Methode liefert einige Kennzahlen, wie die Genauigkeit sowie den `LogLoss`, welche in Unterabschnitt 5.1.1 schon für die Auswertung verwendet wurden. Um ein Modell

zu persistieren, kann es mit `Save()` als ZIP-Datei gespeichert werden. Um das Modell wieder nutzen zu können, wird das Modell mit `Load()` geladen und eine `PredictionEngine` erzeugt. Mit diesem Objekt kann die `Predict()`-Methode ausgeführt werden, welche die Vorhersage für die Materialüberkategorie liefert.

```
1 // Load your data
2 var materialsDv = mlContext.Data.LoadFromEnumerable(trainable);
3
4 //Define your training pipeline
5 var pipeline =
6     mlContext.Transforms.Conversion.MapValueToKey("Label", "
          MaterialCategory")
7          .Append(mlContext.Transforms.Text.FeaturizeText("
              MaterialBezeichnungFeaturized", options, "
              MaterialBezeichnung"))
8          .AppendCacheCheckpoint(mlContext)
9          .Append(mlContext.MulticlassClassification.Trainers.
              SdcaMaximumEntropy(featureColumnName: "
              MaterialBezeichnungFeaturized", labelColumnName: "Label"))
10         .Append(mlContext.Transforms.Conversion.MapKeyToValue("
              PredictedLabel"));
11
12 // Train and save the model
13 var model = pipeline3.Fit(split.TrainSet);
14 mlContext.Model.Save(model, materialsDv.Schema, MODEL_PATH);
15 //Evaluate the model
16 var testdata = model.Transform(split.TestSet);
17 var evaluation = mlContext.MulticlassClassification.Evaluate(testdata);
```

Codeauflistung 6.2: vereinfachter Code für das Trainieren des Materialklassifizierungsmodells mit *ML.NET*

6.3.4 Training des *fastText* Modells

Für das Trainieren des *fastText*-Modells wird die Python-Bibliothek *Gensim* (vgl. Řehůřek and Sojka, 2010) verwendet. Die Bibliothek implementiert verschiedene Vektorisierungsalgorithmen, wie zum Beispiel *Word2Vec*, *EnsembleLDA* aber auch *fastText*.

Über eine interne Schnittstelle wurden alle ADE-Texte in Textdateien gespeichert. Der Trainingsablauf wurde in drei Skripte aufgeteilt. Das Skript *fasttext_prepare.py* liest die Katalogtexte ein und führt das in Unterabschnitt 4.3.3 erläuterte Preprocessing aus. Das Skript *fasttext_train.py* liest die vorverarbeiteten Texte wieder ein, teilt sie in Sätze ein

und generiert Tokens aus jedem Satz. Bei der Aufteilung in Sätze werden Abkürzungen, in denen ein Punkt vorkommt, beachtet und führen zu keinem eigenen Satz. Anschließend wird ein *fastText*-Modell initialisiert, trainiert und am Ende gespeichert.

Mit dem dritten Skript *fasttext_test.py* kann man das trainierte Modell fachlich bewerten. Mit der Methode `most_similar(positive=[word],topn=100)` werden die 100 ähnlichsten Wörter zu einem Wort ausgegeben. Da der Algorithmus DBSCAN mit der Dichte von Punkten und somit der „Ähnlichkeit“ von Worten funktioniert, ist diese Methode eine gute Möglichkeit das Modell fachlich zu evaluieren und testen.

6.3.5 Ausführen der Feinstrukturierung

Die Feinstrukturierung wird im Pythonskript *dbscan_structurize.py* ausgeführt und kann parallel abgearbeitet werden. Nachdem das *fastText*-Modell geladen wurde, werden für jede Überkategorie mit mehr als zwei Materialien ein Threat für die Feinstrukturierung gestartet. Den folgenden Ablauf kann man in zwei Schritte einteilen. Da die Begriffe schon bei der Textklassifizierung durch das Preprocessing gelaufen sind, ist das nicht mehr nötig. Der erste Schritt ist das Vektorisieren der Materialbezeichnungen. Hier werden die Begriffe mit `tokenize()` in die einzelnen Wörter geteilt und dann der Vektor durch die Summe aller Wortvektoren ermittelt. Hierzu werden die Wörter nacheinander mit dem *fastText*-Modell in Vektoren umgewandelt und dann aufaddiert. Danach beginnt der zweite Schritt des Clusterings. Der DBSCAN-Parameter *min_samples* wird auf 2 gesetzt, damit Cluster ab zwei Materialien entstehen können. Über den Parameter *eps* wird von 0,5 bis 5 in 0,1-Schritten iteriert. Da jede Ausführung von DBSCAN andere Eingabevektoren hat, muss auch der Parameter *eps* immer anders gewählt werden, um das optimale Ergebnis zu bekommen. Das optimale Ergebnis bedeutet, möglichst viele verschiedene Cluster zu erhalten und dabei den Median der Anzahl der Rauschpunkte bei dieser Anzahl von möglichst vielen Clustern zu haben. Bei der Iteration über den Parameter kann das optimale Ergebnis, durch Evaluieren der jeweiligen Clusteranzahl und Anzahl von Rauschpunkten, ermittelt werden. Der Startwert und Endwert haben sich durch Testen als passende Werte ergeben, sodass das optimale Ergebnis immer innerhalb des Bereiches liegt. Am Ende wird das optimale Ergebnis an den ASP.NET Service zurückgegeben. Dort wird der Rückgabewert in eine passende Objektstruktur abgebildet und als DTO als HTTP-Response zurückgegeben.

7 Maßnahmen zur Qualitätssicherung

Dieses Kapitel beinhaltet Clean Code Prinzipien und technische Hilfsmittel sowie Unit-Tests, um die Qualitätssicherung sicherzustellen.

7.1 Clean Code

Definition 7 (Clean Code)**.** *„Clean code is simple and direct. Clean code reads like well-written prose. Clean code never obscures the designer's intent but rather is full of crisp abstractions and straightforward lines of control. - Grady Booch author of Object Oriented Analysis and Design with Applications“ (Martin and Coplien, 2009, p. 8)*

Um die Qualitätssicherung bereits vor der Ausführung von Tests sicherzustellen, gilt es gewisse Clean Code Konventionen adäquat anzuwenden. Durch die Verwendung von SonarCloud und SonarLint wird die Anwendung der Code Konventionen sichergestellt. SonarLint führt Analysen während des Programmierens durch und gibt dementsprechend Warnungen bzw. Fehler aus. Welche Konventionen SonarLint analysiert, ist über eine Konfigurationsdatei steuerbar. So ist der Entwickler gezwungen, schon beim Entwickeln die verschiedenen Aspekte von Clean Code zu beachten. Zusätzlich läuft mit SonarCloud eine statische Codeanalyse in der Build-Pipeline. Diese verhindert, dass unkonventioneller Code eingecheckt werden kann. Für den entwickelten Service wurden am Ende der Entwicklung keine Code Smells gefunden. Auch ein Security-Scanner ist in die Build-Pipeline integriert, um Sicherheitsrisiken zu erkennen. Außerdem werden Code Reviews bei einem Pull Request durchgeführt. Durch das Vier-Augen-Prinzip werden so zusätzlich Fehler und Code Smells reduziert.

7.2 Technische Hilfsmittel

Bei der Durchsetzung von Maßnahmen der Qualitätssicherung wurden technische Hilfsmittel verwendet. Diese sind Visual Studio, Visual Studio Code, Azure Data Studio und Azure DevOps. Auf diese wird in diesem Abschnitt eingegangen. Alle benötigten

Lizenzen werden von der „ORCA Software GmbH“ zur Verfügung gestellt. Die Implementierung des ASP.NET-Service wird mit Visual Studio Enterprise 2022 von Microsoft durchgeführt. Die Pythonskripte wurden mit Visual Studio Code implementiert. Mit der „Python“ Erweiterung kann der entwickelte Code direkt ausgeführt und gedebugged werden. Für das Verwalten der SQL-Datenbanken wird Azure Data Studio genutzt. Beim Entwickeln wird eine lokale Datenbank verwendet. Diese wird mit *EntityFramework* und dem Code-First Ansatz automatisch erzeugt. Mit SQL-Statements über Azure Data Studio können die Daten aber manuell eingesehen oder editiert werden.

Das Projektmanagement (siehe Abschnitt 2.1) wird mit Azure DevOps umgesetzt. In diesem werden theoretische Arbeiten durchgeführt, als auch alle praktischen Aufgaben, damit alle Daten an einem zentralen Ort sind. Die Plattform hilft dabei, Maßnahmen zur Qualitätssicherung zu treffen und umzusetzen. Zu Beginn wurde alle bekannten Aufgaben in Pakete unterteilt. Diese Aufgaben wurden schriftlich formuliert und anschließend als User Stories und Tasks in Azure DevOps eingetragen. Im Sprint Planning wurden dann dementsprechende User Stories dem Sprint zugewiesen. Nachdem ein neuer Quellcode verfasst oder alter Quellcode geändert wurde, wurde dieser auf den Azure DevOps Server geladen und mit dem zugehörigen Arbeitselement verknüpft. Bevor der Stand in das Remote Repository integriert wird, startet eine Pipeline. Diese kompiliert den neuen oder geänderten Quellcode, führt die genannten Analysen aus und testet, ob alle Tests erfolgreich durchlaufen. Die Nutzung ist lizenzpflichtig.

7.3 Tests und Abnahme

Um einen funktionsfähigen Service zur Verfügung stellen und sicher weiterentwickeln zu können, muss dieser ausreichend getestet werden. Für den ASP.NET-Service werden dafür Unit-Tests implementiert. Diese werden auch in der Build-Pipeline geprüft. Getestet wird vor allem die Controllerlogik, Pythonlogik und Repositorylogik. Controller können mithilfe von Mocking der genutzten Repositories und Services realisiert werden. Die Pythonskripte wurden inklusive des Python-Interop mit der Klasse `IPythonKiExcuter` getestet. Somit muss keine weitere Unit-Test-Bibliothek verwendet werden. Beim Testen von Repositories wird mithilfe des *In-memory Provider* von *EntityFramework* die Datenbank im Arbeitsspeicher emuliert. So können Zugriffe während des Tests durchgeführt werden, ohne eine echte Datenbank zu benutzten.

Da im Rahmen dieser Arbeit die Nutzung der Materialstrukturierung temporär nur in einem Draft-Projekt implementiert ist und noch keine komplette Integration in die ORCA AVA stattgefunden hat, gibt es eine fachliche Abnahme der Strukturierung der

Materialien. In einem Meeting mit dem Entwicklungsleiter und dem Projektmanagement wurde das Ergebnis der Strukturierung durchgesprochen und die zukünftige Verwendung diskutiert. Die Implementierung als Kostengliederungsimport ist weiterhin vorgesehen und wird in Abschnitt 8.2 behandelt.

8 Abschluss

In diesem letzten Kapitel wird ein Fazit gezogen, die Integration in die ORCA AVA aufgezeigt und ein Ausblick gegeben.

8.1 Fazit

In diesem Abschnitt werden die Ergebnisse der Forschung und praktischen Arbeit zusammengefasst, interpretiert und überprüft, ob das Ziel der Arbeit erreicht wurde. Am Ende werden Beschränkungen der Arbeit aufgezeigt.

Zusammenfassung der Ergebnisse

Zu Beginn wurde die Arbeit motiviert und die Problemstellungen definiert. Dafür wurde das Konzept erarbeitet, einen Webservice bereitzustellen, der die Materialstrukturierung in den drei Schritten ausführt. Diese sind das Preprocessing, die Textklassifizierung und die Feinstrukturierung eingeteilt. Für die Materialstrukturierung wurden dazu zu den Anforderungen passende Algorithmen verglichen und ausgewählt. Diese wurden nach den jeweiligen Kriterien der Messbarkeit und in der fachlichen Abstimmung mit dem Produktmanagement evaluiert. Für die Textklassifizierung und die Feinstrukturierung wurde jeweils ein passender Algorithmus gefunden. Die funktionalen Anforderungen wurden mit einem RESTfull ASP.NET Service realisiert. Dieser führt mithilfe von Python-Interop die Materialstrukturierung durch. Die Textklassifizierung wird mit *ML.NET* und einem Maximum Entropy Modell mit dem SDCA-Optimierungsalgorithmus durchgeführt. Bei der Feinstrukturierung stellte sich das Nutzen von DBSCAN mit einer voraus liegenden *fastText*-Vektorisierung als passend heraus. Die Daten für die Strukturierung werden in einer SQL-Datenbank persistiert. Zusätzlich entstand ein Draftprojekt, um den Service visuell ansteuern zu können. Dafür wurde die Extraktion aller Materialien aus einer IFC-Datei für den IFC Manager implementiert. Die Maßnahmen der Qualitätssicherung wurden erläutert.

Zielerreichung

Zu Beginn der Arbeit wurde unter Abschnitt 1.3 ein Ziel mit der SMART Methode definiert. Die für das Ziel definierten Anforderungen konnten durch die theoretische Konzeption in Kapitel 4, die Gegenüberstellung der Algorithmen in Kapitel 5 und die Implementierung in Kapitel 6 umgesetzt werden. Auch die Maßnahmen zur Qualitätssicherung wurden umgesetzt und verifiziert. Bei der Evaluation wurden die Kriterien der Messbarkeit beachtet. Die Evaluation, Auswahl und Implementierung lieferten ein brauchbares Ergebnis für die Strukturierung der Materialien, welches vom Produktmanagement freigegeben wurde. Ein Draftprojekt wurde vollständig erstellt. Somit wurde das definierte Ziel der Arbeit vor Ablauf der Zeitbegrenzung erreicht.

Textklassifizierung

Die Textklassifizierung mit *ML.NET* und einem Maximum Entropy Modell mit dem SDCA-Optimierungsalgorithmus lieferte trotz Problemstellung 3 (Materialien sind nur Stichpunkte aus wenigen Worten) mit einer Genauigkeit von 88 % ein gutes Ergebnis. Mit der Erweiterung der Trainingsdaten kann das Modell noch robuster und auch genauer trainiert werden. Die Implementierung in Python war hier nicht nötig und die Bibliothek *ML.NET* bietet ausreichende Möglichkeiten an, die Textklassifizierung durchzuführen.

Feinstrukturierung

Für die Feinstrukturierung beweist sich das Nutzten einer domänenspezifischen Lösung. Das Trainieren eines *fastText*-Modells mit Ausschreibungstexten aus der Baubranche bietet dem simplen Clustering-Algorithmus DBSCAN es, nach der Bedeutung eines Wortes zu strukturieren. Somit wurde Problemstellung 3 und Problemstellung 4 gelöst und ein fachlich nutzbares Ergebnis erzielt. Auch wenn das manuelle Testen des *fastText*-Modells mit der `most_similar()`-Methode kein gutes Ergebnis versprach, war das Ergebnis beim Clustering fachlich nutzbar. Die Ähnlichkeit der Worte im *fastText*-Modell sind für das Ergebnis nicht wichtig.

Beschränkungen der Arbeit

Neben den behandelten Algorithmen und Bibliotheken wurden weitere Möglichkeiten nur sporadisch untersucht und getestet. Eine erste Recherche hat auf die in der Arbeit untersuchten Lösungen hingewiesen. Alle Möglichkeiten zu analysieren würde über den Rahmen der Arbeit hinausgehen. Falls das Ergebnis der Gegenüberstellung aus Gründen in der Zukunft nicht mehr infrage kommt, können weitere Möglichkeiten

wieder aufgegriffen und in Betracht gezogen werden. Zusätzlich lag der Fokus auf dem Finden passender Algorithmen. Es wurde in der Codebasis der ORCA AVA nur die Möglichkeit bereitgestellt, alle Materialien aus einer IFC-Datei zu extrahieren. Die Programmerweiterung der Materialkostengliederung wurde nicht komplett implementiert. In Abschnitt 8.2 wird diese Integration beschrieben und ein Vorschlag geliefert.

8.2 Integration in die ORCA AVA

Da der Service vollumfänglich implementiert ist und das Ergebnis der Strukturierung gut genug ist, kann als nächstes die Integration in die ORCA AVA beginnen. Technisch ist eine Kostengliederung als Modell im C# Code definiert. Der Aufbau bildet die Baumstruktur über eine Referenz zur ParentNode und mehreren ChildrenNodes ab. Das Model kann über die ORCA AVA interne Middleware in der Datenbank persistiert werden. Die persistierten Kostengliederungen werden dann in entsprechenden Programmteilen angezeigt. So müssen nach der generierten Kostengliederungs-Struktur die strukturierten Materialbezeichnungen in die C# Objektstruktur abgebildet werden. So wird nach dem Import die erstellte Kostengliederung automatisch in der Oberfläche angezeigt und kann für Kostenauswertungen genutzt werden. Neben dem Import einer Materialkostengliederung wird nebenbei ein Import einer Raumkostengliederung aus einer IFC-Datei implementiert, welcher diese Vorgehensweise bereits implementiert. Die Implementierung muss somit nur bei der Beschaffung der Daten aus der IFC-Datei, auf den schon implementieren `MaterialManager` zugreifen. In der Oberfläche soll der Import dann über das Kontextmenü *Neu* im Programmteil der Kostengliederung zur Verfügung gestellt werden.

8.3 Ausblick

In diesem Abschnitt wird ein Ausblick auf die Programmerweiterung der Materialstrukturierung gegeben. Nachdem die Integration in die ORCA AVA vorgeschlagen wurde, kann diese jetzt auch als nächstes realisiert werden. Die Erweiterung könnte in der Version 26 in der ORCA AVA Enterprise Edition erscheinen. In der Zukunft können danach auch weitere Schritte folgen, um den IFC-First Ansatz zu realisieren. Hier wird auch der Einsatz von Machine Learning sowie NLP sinnvoll sein. Es muss zum Beispiel anhand der Attribute eines IFC-Bauteils ein Ausschreibungstext erstellt werden.

Eine weitere Nutzungsmöglichkeit der Materialstrukturierung ist das Ermitteln der CO_2-Bilanz eines Gebäudes über eine IFC-Datei. Wenn man bei der Extraktion der

Materialien die Mengenangabe inkludiert, kann mithilfe von Umweltdatenbanken und deren CO_2-Durchschnittswerte für verschiedene Materialien die CO_2-Bilanz der Baustoffe eines Gebäudes ermittelt werden. Dabei hilft die Strukturierung der Materialien, es müsste aber eine Zuweisung zu den entsprechenden Datenbankeinträgen passieren.

A Anhang

Abbildungen

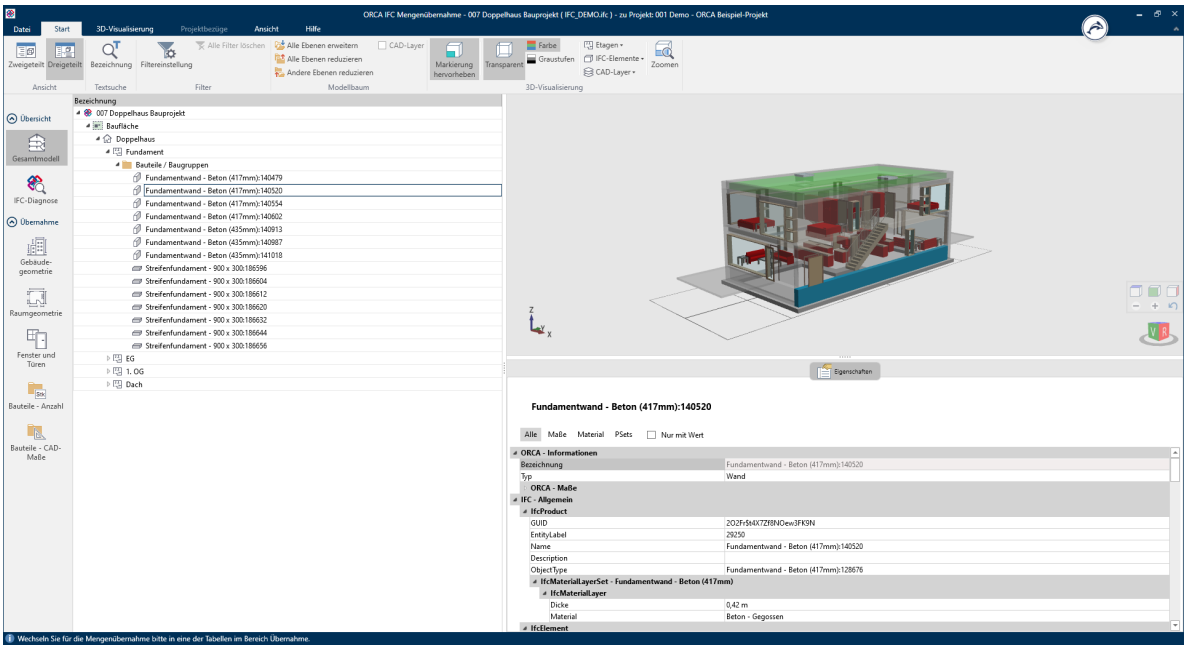

Abbildung A.1: Oberfläche des IFC Manager

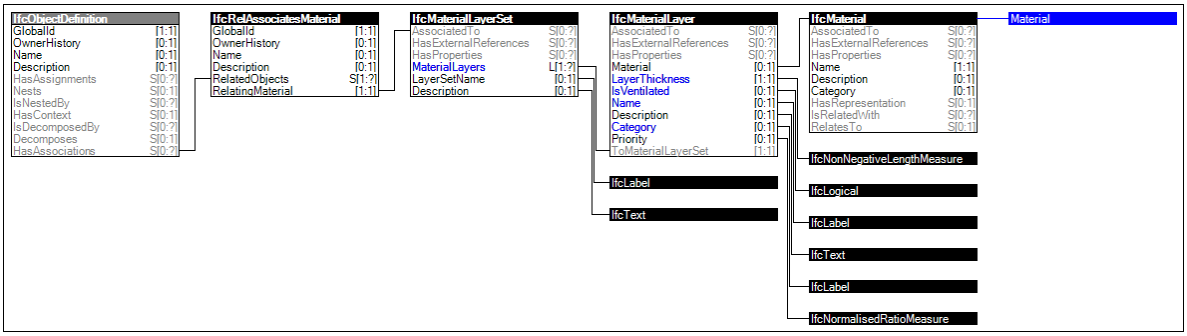

Abbildung A.2: Material Layer Set Association

Metall	*Eisen & Stahl*	**Eisen und Stahl**
		Baustahl · Betonstahlmatte · Betonstabstahl · Spannbetonstahl · Gusseisen · Profilstahl
	Nichteisen	**Nichteisenmetalle**
		Aluminium · Magnesium · Blei · Zinn · Zink · Kupfer
Glas	*Glas*	**Glas**
		Glasbaustein · Flachglas · Pressglas
Holz	*Holz*	**Holz**
		Bauholz · Furniersperrholz · Leimbinder · Sperrholz · Grobspanplatte · OSB-Platte · Brettschichtholz · MDF-Platte · Flachpressplatte · Multiplex-Platte · Holzwolle · Strangpressplatte
Kunststoff	*Thermoplaste*	**Kunststoffe (Thermoplaste)**
		Ethylen-Tetrafluorethylen (ETFE) · Polyvinylchlorid (PVC) · Polyethylen (PE) · Polypropylen (PP) · Polymethylmethacrylat (PMMA) · Polystyrol (PS) · Polyvinylacetat (PVAC) · Polycarbonat (P
	Duroplaste	**Kunststoffe (Duroplaste)**
		Phenol-Formaldehyd-Harz („Bakelit", PF) · UF-Harz · Melamin-Formaldehyd-Harz (MF) · ungesättigtes Polyester-Harz (UP) Epoxidharz (EP)
	Elastomere	**Kunststoffe (Elastomere)**
		Polyurethan (PUR) · Kautschuk · Silikone · Acryl
Bitumen & Teer		**Dichtstoffe**
		Bitumen · Noppenbahn
		Asphalt
		Walzasphalt · Gussasphalt · Naturasphalt · Halbstarrer Belag
Mineralisch		**Natürliche und künstliche Gesteinskörnungen**
		Sand · Kies · Bims · Hochofenschlacke · Hüttenbims · Blähton · Blähschiefer
		Mörtel
		Mauermörtel · Putzmörtel · Estrichmörtel · Fliesenkleber
	Beton	**Beton**
		Leichtbeton · Normalbeton · Schwerbeton · Stahlbeton · Spannbeton · Faserbeton · Stahlfaserbeton · Porenbeton
	Naturwerkstein	**Natürliche Bausteine (Naturwerksteine)**
		Sandstein · Kalkstein · Granit · Schiefer · Marmor · Tuff · Grauwacke · Rhyolith · Basalt und andere
		Künstliche Bausteine
		Ziegel · Klinker · Tonhohlplatte · Dachziegel · Kalksandstein · Hüttenstein · Betonstein · Leichtbetonstein · Schwerbetonstein · Porenbeton · Betonwerkstein · Betondachstein · Bläh
Verbundbauteile		Fenster, Fassaden, ...
Dämmungen (siehe Arbeitsblatt Dämmstoffe)		**Dämmstoffe**
		Flachsfasern · Holzwolle-Leichtbauplatte (z. B. Heraklith) · Holzweichfaserplatte · Getreideschüttungen (Ceralith) · Glasfaserdämmstoff · Hanffasern · Mineralfaserdämmstoff · Sch
Gebäudetechnik (?)		
Sonstiges		

Abbildung A.3: Überkategorien für die Klassifizierung von Materialien mit Beispielen

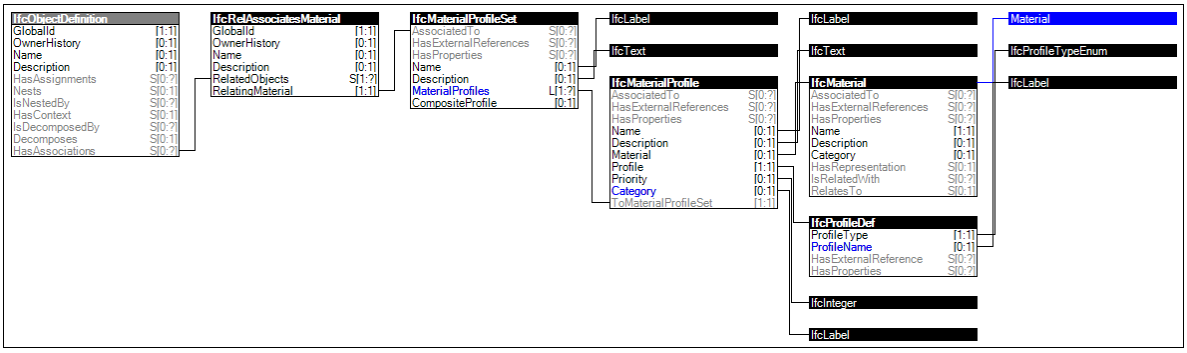

Abbildung A.4: Material Profile Set Association

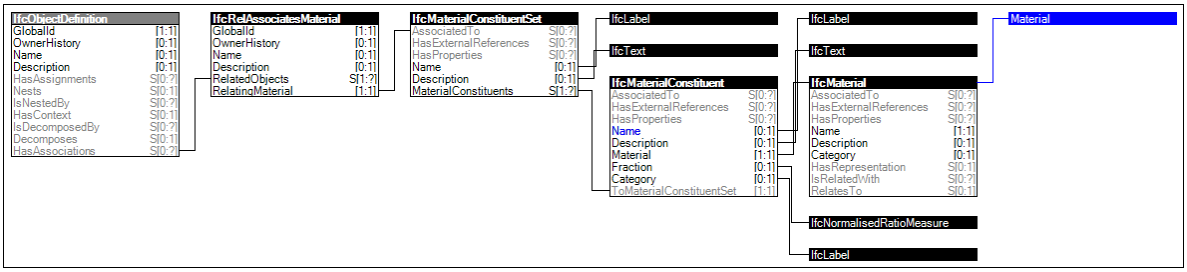

Abbildung A.5: Material Constituent Set Association

Abbildung A.6: Beispiel einer Kostengliederung in der ORCA AVA

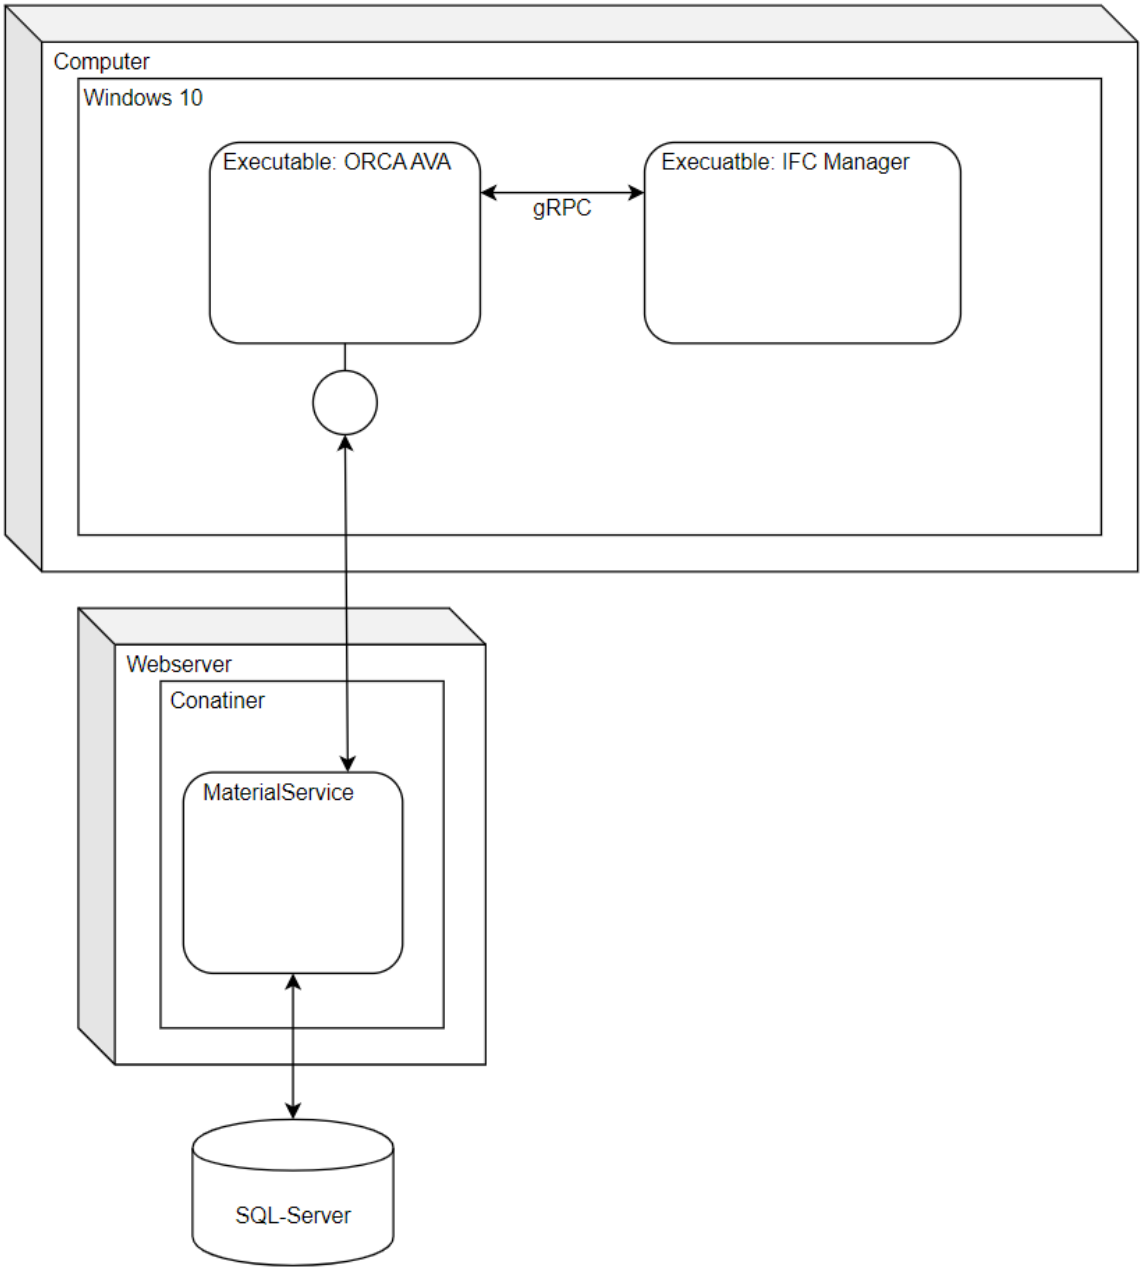

Abbildung A.7: Verteilungsdiagramm der Architektur

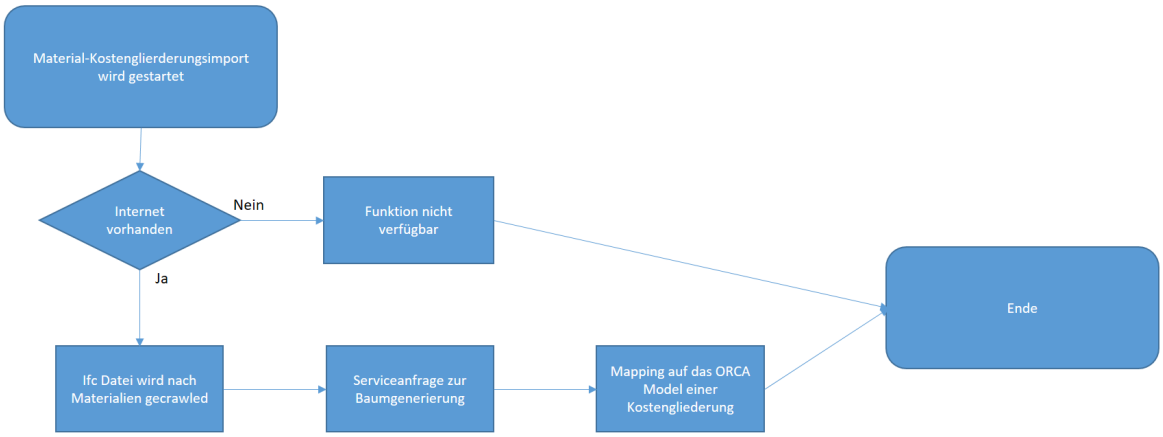

Abbildung A.8: Flussdiagramm Import der Material-Kostengliederung

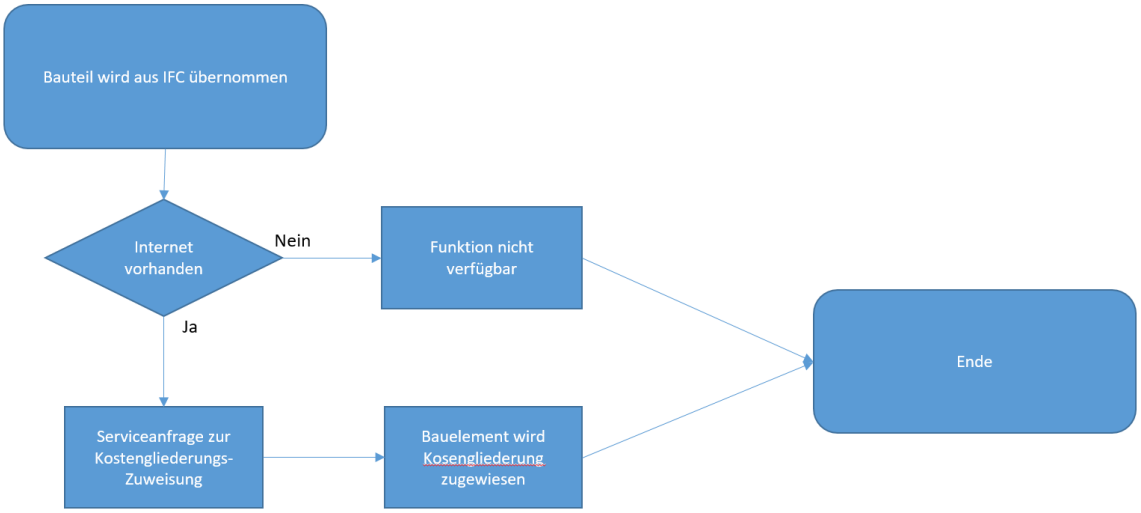

Abbildung A.9: Flussdiagramm Übernahme von Mengen aus dem IFC Manager

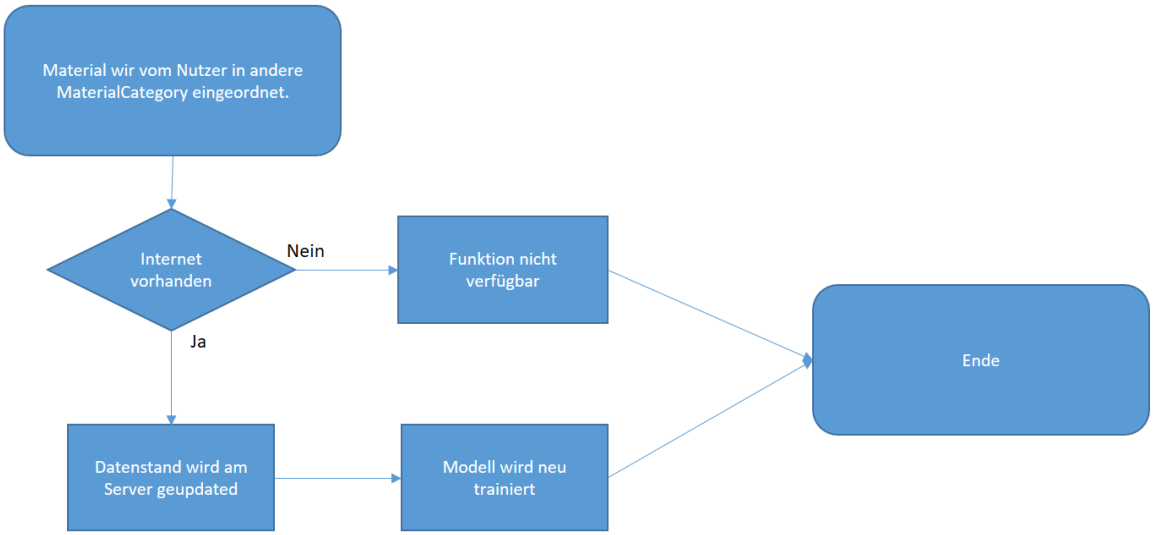

Abbildung A.10: Flussdiagramm Bewertung des Kostengliederungs-Import

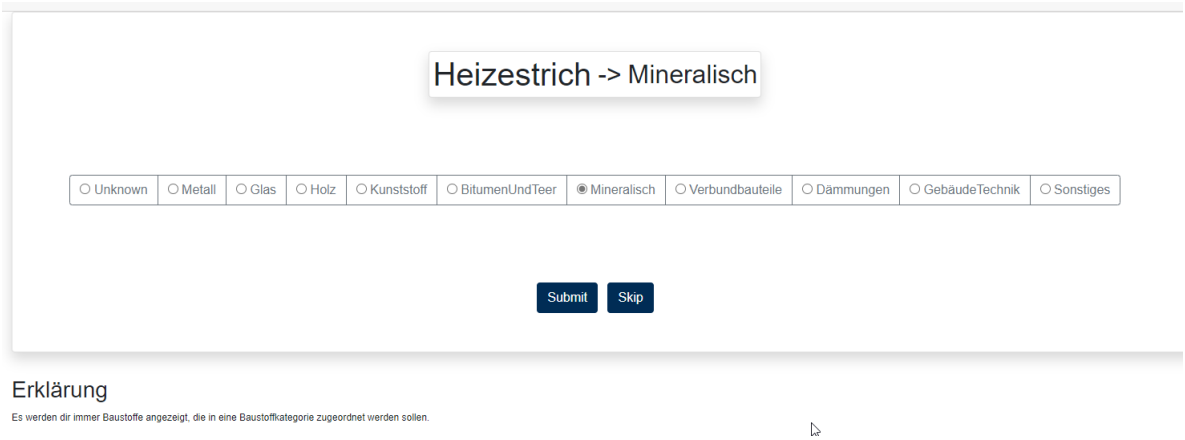

Abbildung A.11: Oberfläche des Klassifizierungs-Tools für Materialien

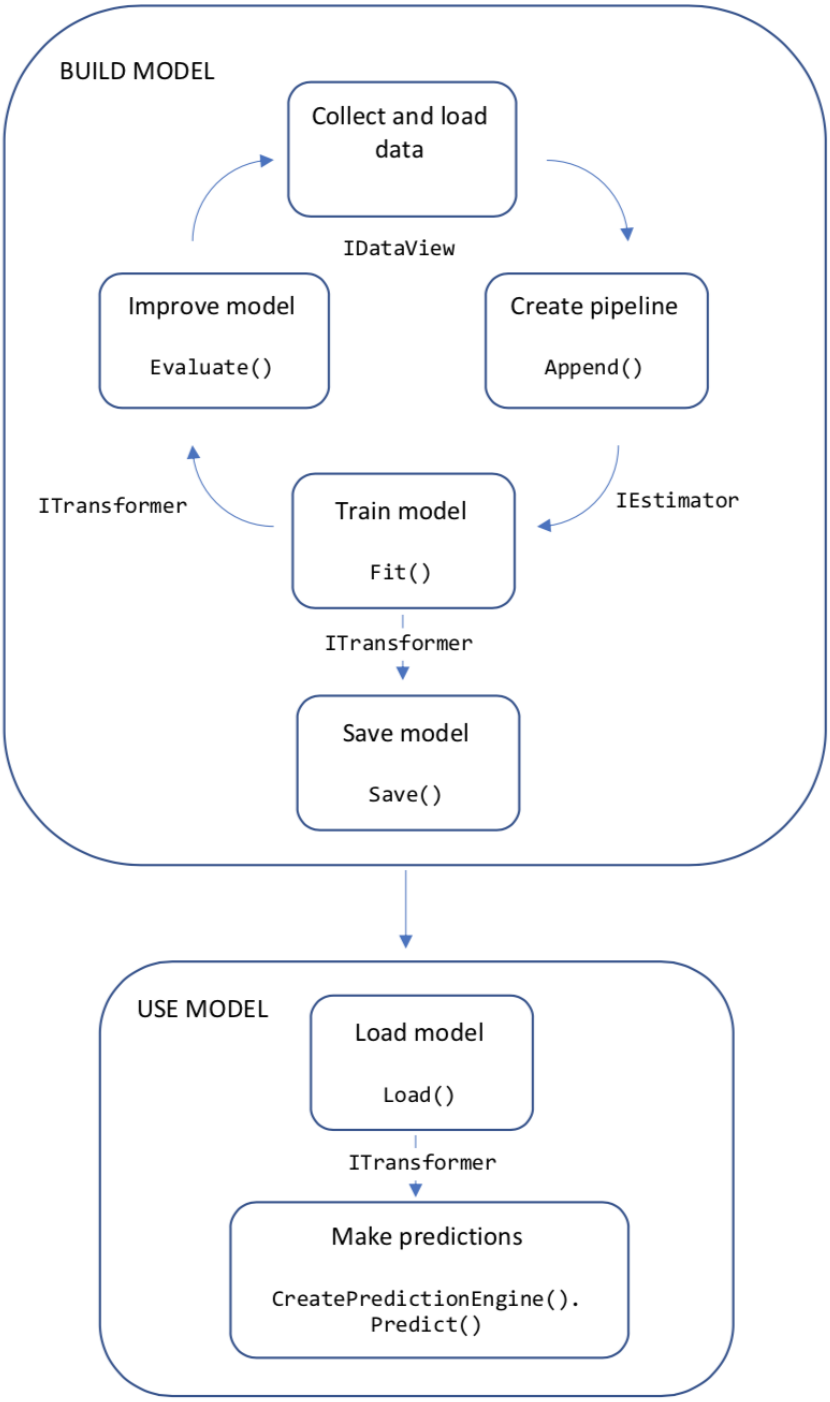

Abbildung A.12: Code Workflow von *ML.NET* (Quelle: Microsoft (2022*c*))

Listings

```
1 public async Task<CostStructureDto> GenerateMaterialCostStructureAsync(
      ICollection<string> materialNames, bool structurizeFine)
2 {
3     if (materialNames is null)
4         throw new ArgumentNullException(nameof(materialNames));
5
6     materialNames = materialNames.Distinct().ToArray();
7
8     List<Material> materials = await mMaterialRepository.CreateNewAsync
          (materialNames
9         .Select(name =>
10            new Material()
11            {
12                MaterialBezeichnung = name,
13                Appearances = 1
14            }));
15
16    ICollection<MaterialStructureNode> result = mMaterialStructorizer
17        .StructurizeMaterials(materials.Select(m => m.
              PreprocessedMaterialBezeichnung).ToArray(), structurizeFine
              );
18
19    var dto = new CostStructureDto();
20    dto.SetMaterials(result.Select(r => r.ToDto()).ToList());
21    return dto;
22 }
```

Codeauflistung A.1: Implementierung der Methode `GenerateMaterialCostStructureAsync` der Klasse `MateialService`

```
1 public static readonly string ModelPreprocess = "preprocess";
2 public static readonly string InputPreprocess = "material_raw";
3 public static readonly string OutputPreprocess = "material_preprocessed
      ";
4
5 public string PreprocessMaterial(string material)
6 {
7     try
8     {
9         PythonEngine.Initialize();
```

```
10
11          using (Py.GIL())
12          {
13              using (PyModule scope = Py.CreateScope())
14              {
15                  dynamic preprocessScript = scope.Import(
                        PythonKiExecuterConstants.ModelPreprocess);
16                  string materialPreprocessed = preprocessScript.
                        preprocess(material);
17
18                  return materialPreprocessed;
19              }
20          }
21      }
22      catch (Exception ex)
23      {
24          Console.WriteLine(ex.Message);
25          throw;
26      }
27      finally
28      {
29          PythonEngine.Shutdown();
30      }
31  }
```

Codeauflistung A.2: Python-Interopt für das Preprocessing

```
1  import re
2  words_to_remove = ['rot','blau','gelb','grün','gruen','weiß','weiss','
       schwarz','grau','rosa','pink','lila','braun','gold','silber','
       orange','dunkelgrau','beige','dunkel','hell']
3  material_raw:str
4  material_preprocessed:str
5
6  def preprocess(material_name):
7      old = material_name;
8      material_name = re.sub(r'[\d]{1,3}[\s_-]+[\d]{1,3}[\s_-]+[\d]{1,3}'
           ,'',material_name);
9      #remove special characters eg ,.-;:_
10     material_name = (" ".join(re.findall(r"[A-Za-z0-9üäöÜÄÖßóåéèÉÉÓ/]*"
           , material_name))).replace("  "," ");
11     #remove size and add afterwards as one
12     size_threedimensional = re.compile('[\d]{1,4}[\s]?[x][\s]?[\d
           ]{1,4}([\s]?[x][\s]?[\d]{1,4})?');
```

```
13      size_twodimensional = re.compile('[\d]{1,4}[\s]?[x][\s]?[\d]{1,4}')
            ;
14      # size = re.findall('[\d]{1,4}[\s]?[x][\s]?[\d]{1,4}[\s]?[x][\s]?[\
            d]{1,4}', material_name);
15      size = re.findall('[\d]{1,4}[\s]?[x][\s]?[\d]{1,4}([\s]?[x][\s]?[\d
            ]{1,4})?', material_name);
16      if len(size) <= 0:
17          size = re.findall(size_twodimensional, material_name);
18      material_name = re.sub(size_threedimensional,'',material_name);
19      for word in words_to_remove:
20          if word in material_name.lower():
21              index = material_name.lower().index(word);
22              if index >= 0:
23                  material_name = material_name[:index] + material_name[
                        index+len(word):];
24      while('  ' in material_name):
25          material_name = material_name.replace('  ',' ')
26      material_name = material_name.strip();
27      print(f"'{old}' -> '{material_name}'")
28      return material_name;
29
30  print(__name__);
31  if __name__ == "__main__":
32      try:
33          material_raw
34      except NameError:
35          material_raw = input("Text to preprocess: ")
36      material_preprocessed = preprocess(material_raw)
37      print(material_preprocessed)
```

Codeauflistung A.3: Python-Interopt für das Preprocessing

Tabellen

Predicted ->		0	1	2	3	4	5	6	7	8	9		Recall
Truth													
Mineralisch		22	0	0	0	0	2	0	0	0	0		0,9167
Sonstiges		4	8	0	0	0	0	0	0	0	0		0,6667
Dämmungen		0	0	7	0	0	0	0	0	0	0		1,0000
Holz		0	0	0	7	0	0	0	0	0	0		1,0000
Verbundbauteile		1	0	0	0	5	0	0	1	0	0		0,7143
Metall		2	1	0	0	0	25	0	0	0	0		0,8929
Kunststoff		0	0	0	0	0	0	4	0	0	0		1,0000
Glas		0	0	0	0	0	0	0	4	0	0		1,0000
GebäudeTechnik		0	0	0	0	0	0	0	0	1	0		1,0000
BitumenUndTeer		0	0	0	0	0	0	0	0	0	0		0,0000
Precision		0,7586	0,8889	1,0000	1,0000	1,0000	0,9259	1,0000	0,8000	1,0000	0,0000		

Tabelle A.1: Konfusionsmatrix: ScdaMaximumEntropy

Predicted ->		0	1	2	3	4	5	6	7	8	9		Recall
Truth													
0. Mineralisch		23	0	0	0	0	1	0	0	0	0		0,9583
1. Sonstiges		9	3	0	0	0	0	0	0	0	0		0,2500
2. Dämmungen		4	0	3	0	0	0	0	0	0	0		0,4286
3. Holz		1	0	0	6	0	0	0	0	0	0		0,8571
4. Verbundbauteile		4	0	0	0	3	0	0	0	0	0		0,4286
5. Metall		10	0	0	0	0	18	0	0	0	0		0,6429
6. Kunststoff		1	0	0	0	0	0	3	0	0	0		0,7500
7. Glas		0	0	0	0	0	0	0	4	0	0		1,0000
8. GebäudeTechnik		1	0	0	0	0	0	0	0	0	0		0,0000
9. BitumenUndTeer		0	0	0	0	0	0	0	0	0	0		0,0000
Precision		0,4340	1,0000	1,0000	1,0000	1,0000	0,9474	1,0000	1,0000	0,0000	0,0000		

Tabelle A.2: Konfusionsmatrix: LbfgsMaximumEntorpy

Predicted ->		0	1	2	3	4	5	6	7	8	9		Recall
Truth													
0. Mineralisch		22	0	0	0	0	2	0	0	0	0		0,9167
1. Sonstiges		4	8	0	0	0	0	0	0	0	0		0,6667
2. Dämmungen		0	0	7	0	0	0	0	0	0	0		1,0000
3. Holz		0	0	0	7	0	0	0	0	0	0		1,0000
4. Verbundbauteile		1	0	0	0	4	1	0	1	0	0		0,5714
5. Metall		2	1	0	0	0	25	0	0	0	0		0,8929
6. Kunststoff		0	0	0	0	0	0	4	0	0	0		1,0000
7. Glas		0	0	0	0	0	0	0	4	0	0		1,0000
8. GebäudeTechnik		0	0	0	0	0	0	0	0	1	0		1,0000
9. BitumenUndTeer		0	0	0	0	0	0	0	0	0	0		0,0000
Precision		0,7586	0,8889	1,0000	1,0000	1,0000	0,8929	1,0000	0,8000	1,0000	0,0000		

Tabelle A.3: Konfusionsmatrix: OneVersusAll

Predicted ->		**0**	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**		**Recall**
Truth													
0. Mineralisch		21	0	0	0	0	3	0	0	0	0		0,8750
1. Sonstiges		6	3	0	0	0	3	0	0	0	0		0,2500
2. Dämmungen		7	0	0	0	0	0	0	0	0	0		0,0000
3. Holz		5	0	0	1	0	1	0	0	0	0		0,1429
4. Verbundbauteile		6	0	0	0	0	1	0	0	0	0		0,0000
5. Metall		11	0	0	0	0	17	0	0	0	0		0,6071
6. Kunststoff		1	0	0	0	0	0	3	0	0	0		0,7500
7. Glas		2	0	0	0	0	2	0	0	0	0		0,0000
8. GebäudeTechnik		1	0	0	0	0	0	0	0	0	0		0,0000
9. BitumenUndTeer		0	0	0	0	0	0	0	0	0	0		0,0000
Precision		0,3500	1,0000	0,0000	1,0000	0,0000	0,6296	1,0000	0,0000	0,0000	0,0000		

Tabelle A.4: Konfusionsmatrix: TextclassificationersusAll

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Ortbeton C30/37 Verputzt	1	1	
Trockenbau Gipsplatte			
Fußboden Heizestrich	3	3	3
Geländearbeiten Gebundene Schüttung	4	4	4
Ortbeton C30/37	1	1	
Mauerwerk mit Daemmeigenschaften	2	2	2
Fußboden Fußbodenaufbau	3	3	3
Fußboden Schüttung	3		3
Putz			
Geländearbeiten Rollierung Schuettung	4	4	4
Ortbeton bewehrt geschliffen	1		
Geländearbeiten Aufgeschüttet	4	4	4
Fußboden Estrich	3	3	3
Beton C 25/30	1	1	
Dachdeckung Ziegel			
Mauerwerk ohne Daemmeigenschaften	2	2	2
Auswertung	richtig	teilweise	teilweise

Tabelle A.5: Überkategorie: Mineralisch

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Keramik			
Trockenbau Gipsplatte	1	1	1
Trockenbau Gipsplatte 2	1	1	1
Trockenbau Gipsplatte 3	1	1	1
Trockenbau Gipsplatte 4	1	1	1
Fußboden Teppich	2		2
Fußboden Estrich	2		2
Fußboden Trittschall	2	2	2
Fußboden Schüttung	2	2	2
Geschossdecke FB 200 Fliese	3	3	
Fußboden Fliese Travertin	2	3	2
Ortbeton bewehrt	3		
Mauerwerk Ziegel			
Auswertung	richtig	falsch	teilweise

Tabelle A.6: Überkategorie: Mineralisch

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Gipskarton			
Keramik Fliesen			
Mauerwerk Betonblock	1	1	1
Beton Gegossen	2	2	2
Mauerwerk Ziegel	1	1	1
Beton	2	2	2
Auswertung	richtig	richtig	richtig

Tabelle A.7: Überkategorie: Mineralisch

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Stütze Auflager			-1
Kalksandstein			
Kies			
Fliesen			2
Estrich			2
Gipsputz			
Volkernplatte			1
Ausbauplatte GKBI	1	1	1
Ausbauplatte GKB	1	1	1
Auswertung	richtig	richtig	falsch

Tabelle A.8: Überkategorie: Mineralisch

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
WI KS 17 5	1	1	
Kalksandstein	1		1
WI KS 11 5	1	1	1
DA Flachdach Kiesschicht	3		
Kies	3		
Fliesen			3
Estrich			3
Gipsputz			
Ausbauplatte GKBI	2	2	2
Ausbauplatte GKB	2	2	2
Auswertung	richtig	teilweise	falsch

Tabelle A.9: Überkategorie: Mineralisch

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Mauerwerk Langlochziegel verputzt	1	1	1
Mauerwerk Ziegel verputzt	1	1	1
MW Kalksandstein verputzt	1	1	1
Knauf Bauplatte Typ A			
Decke Fliesen			
Beton Estrich			
Porenbeton verputzt	1	1	
Vorgabe Dach			
Auswertung	richtig	richtig	teilweise

Tabelle A.10: Überkategorie: Mineralisch

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
A W TR MW KS 17 5	4	4	
FAS PUTZ TYP1 0 2 0	1	1	
I BOD ESTRICH ZE 6	2	2	2
I BOD ESTRICH ZE 7	2	2	2
FAS PUTZ TYP1 0 2	1	1	
I BOD BELAG BETONSTEIN 3	3	3	3
I BOD ESTRICH ZE 4	2	2	2
I BOD BELAG FLIESE 1 5	3	3	3
I BOD ESTRICH ZE 5 5	2	2	2
I W TR MW KS 11 5	4	4	
A BOD KIES 5			
Gefällebeton	5		
Beton	5		
Concrete	5		
Auswertung	richtig	teilweise	teilweise

Tabelle A.11: Überkategorie: Mineralisch

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Metall Edelstahl gebürstet	1	1	1
Fensterbank Aussen Blech			-1
Metall Edelstahl Satiniert	1	1	1
Metall Stahl matt		1	
Auswertung	richtig	falsch	falsch

Tabelle A.12: Überkategorie: Metall

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Metall Titanzink		2	
Metall Oberfläche lackiert elfenbein Mit Glaz	1	1	1
Metall Oberfläche lackiert matt	1	1	1
Metall Aluminium		2	
Metall lackiert	1	1	
Metall verzinkt		2	
Auswertung	richtig	richtig	teilweise

Tabelle A.13: Überkategorie: Metall

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Metall Edelstahl Satiniert	1	1	1
Metall Edelstahl gebürstet	1	1	1
Metall Stahl matt	2	1	
Metal Strugal Stainless Steel	1	2	
Aluminum Strugal RAL 9016		2	
Fensterbank Aussen Blech		2	
Auswertung	richtig	falsch	teilweise

Tabelle A.14: Überkategorie: Metall

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
StB C45	1	1	1
StB C55	1	1	1
StB C35	1	1	1
StB C30	1	1	1
StB C60	1	1	1
Fertigteil StB C35	1	1	1
StB FU	1		1
Auswertung	richtig	teilweise	richtig

Tabelle A.15: Überkategorie: Verbundbauteil

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Aluminium			
Stahl verzinkt			
Edelstahl			
Auswertung	richtig	richtig	richtig

Tabelle A.16: Überkategorie: Metall

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
DA Flachdach Gefälledämmung	2	2	1
Mineralwolle 4	1	1	1
WA XPS Dämmung 10cm	3		1
XPS	3	2	1
DA Flachdach Dämmung 14cm	2	2	1
Mineralwolle 3	1	1	1
Brandriegel			
Trittschalldämmung			
Auswertung	richtig	falsch	falsch

Tabelle A.17: Überkategorie: Dämmungen

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
DA Flachdach Dämmung 14cm	3	2	1
Mineralwolle 3	1	1	1
WA XPS Dämmung 10cm	2	2	1
XPS	2		1
DA Flachdach Gefälledämmung	3	2	1
Mineralwolle 4	1	1	1
Trittschalldämmung			
Brandriegel			
Auswertung	richtig	falsch	falsch

Tabelle A.18: Überkategorie: Dämmungen

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
FAS WDVS WD EPS 8	1	1	1
FAS WDVS WD EPS 18	1	1	1
I BOD DAEM TD 3			2
I BOD DAEM WD 14	2	2	2
I BOD DAEM WD 15	2	2	2
A BOD DAEM XPS 11	4	4	4
A W NT DAEM PD XPS 12	3	3	3
A W NT DAEM PD XPS 6	3	3	3
A BOD DAEM XPS 12	4	4	4
A BOD DAEM XPS 10	4	4	4
Auswertung	richtig	richtig	teilweise

Tabelle A.19: Überkategorie: Dämmungen

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Glas Isolierverglasung klar	1	1	1
Glas Isolierverglasung 3 fach	1	2	1
Glas Isolierverglasung 2 fach	1	2	1
Glas klar	1	1	
Glas matt			
Auswertung	richtig	falsch	teilweise

Tabelle A.20: Überkategorie: Glas

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Glas matt			
Glas Isolierverglasung Bronze	1		1
Glass Strugal Clear Glazing	1	2	
Glas klar	1	1	
Glass Simonton Clear	1	2	
Glas Isolierverglasung klar	1	1	1
Auswertung	richtig	falsch	teilweise

Tabelle A.21: Überkategorie: Glas

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Geschossdecke FB 200 Parkett	2	2	-1
Holz generisch		1	
Fußboden Parkett eiche	2	2	-1
Dachdeckung Holz	1	1	1
Dachdeckung Holz 2	1	1	1
Auswertung	richtig	teilweise	falsch

Tabelle A.22: Überkategorie: Holz

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Holz Parkett			1
Holz Birke	1	1	1
Holz Eiche	1	1	1
Standard Treppe			
Auswertung	richtig	richtig	teilweise

Tabelle A.23: Überkategorie: Holz

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Dachdeckung Holz			
Fußboden Terrasse Teakholz			
Holz HSB Steher			
Holz Astfichte senkrecht			
Auswertung	richtig	richtig	richtig

Tabelle A.24: Überkategorie: Holz

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
Fußboden Epoxidharzbeschichtung			
BSt 500 M A	1	1	1
BSt 500 M B	1	1	1
Auswertung	richtig	richtig	richtig

Tabelle A.25: Überkategorie: Verbundbauteile

Begriff	**Erwartet**	**DBSCAN**	**OpenAI**
A W TR STB OB 17 5	1	1	-1
I W TR STB OB 25	1	2	-1
A DE TR STB OB 30	3		-1
I W TR STB OB 12	1	2	-1
A W TR STB OB 25	1	1	-1
A W TR STB OB 30	1	1	-1
I W TR STB OB 22	1	2	-1
I DE TR STB OB 20	3	3	-1
I DE TR STB OB 45	3	3	-1
I DE TR STB OB 25	3	3	-1
Auswertung	richtig	teilweise	teilweise

Tabelle A.26: Überkategorie: Verbundbauteile

B Abkürzungsverzeichnis

IFC Industy Foundation Classes

IFC2x3 IFC Version 2.3

IFC4 IFC Version 4

BIM Building Information Modeling

KG Kostengruppe

DevOps Development Operations

NLP Natural Language Processing

AVA Auschreibung, Vergabe und Abrechung

ADE AUSSCHREIBEN.DE

BIM Building Information Modeling

DIN Deutsches Institut für Normung e. V.

SE Starter Edition

PE Professional Edition

EE Enterprise Edition

VB Visual Basic

GUI Graphical User Interface

WPF Windows Presentation Foundation

ISO International Organization for Standadization

STEP Standard for the exchange of product model data

SPF STEP Physical Format

XML Extensible Markup Language

CAD Computer-aided design

REST Representational State Transfer

KI Künstliche Intelligenz

IoT Internet of Things

RGB Rot,Grün,Blau

API Application Programming Interface

GPT Generative Pretrained Transformer

VB Visual Basic

GUID Globally Unique Identifier

DTO Data Transfer Object

URL Uniform Resource Locator

DBSCAN Density-Based Spatial Clustering of Applications with Noise

CBOW Continuous Bag Of Words

HTTP Hypertext Transfer Protocol

SQL Structured Query Language

SDCA Stochastic dual coordinated ascent

L-BFGS limited memory Broyden-Fletcher-Glodfarb-Shanno method

C Definitionsverzeichnis

D Quellcodeverzeichnis

Literaturverzeichnis

Adriaans, P. (2020), Information, *in* E. N. Zalta, ed., 'The Stanford Encyclopedia of Philosophy', Fall 2020 edn, Metaphysics Research Lab, Stanford University.

Beetz, F. and Harrer, S. (2021), 'GitOps: The Evolution of DevOps?', *IEEE Software* **39**.

Berger, A. L., Pietra, V. J. D. and Pietra, S. A. D. (1996), 'A maximum entropy approach to natural language processing', *Comput. Linguist.* **22**(1), 39–71.

Bie, Q. (2019), 'Words are not enough! Short text classification using words as well as entities'.
URL: *https://www.fiz-karlsruhe.de/sites/default/files/FIZ/Dokumente/Forschung/ISE/Masterarbeiten/Thesis-Qingyuan-Bie.pdf*

Bojanowski, P., Grave, E., Joulin, A. and Mikolov, T. (2017), 'Enriching word vectors with subword information'.

Bojanowski, P., Joulin, A. and Mikolo, T. (2016), 'Fair open-sources fasttext'. Accessed: 2023-4-26.
URL: *https://research.facebook.com/blog/2016/8/fasttext/*

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I. and Amodei, D. (2020), 'Language models are few-shot learners'.

buildingSMART International Ltd. (2017*a*), 'Industry Foundation Classes - IfcMaterial'. Accessed: 2023-1-31.
URL: *http://standards.buildingsmart.org/IFC/RELEASE/IFC4_1/FINAL/HTML/link/ifcmaterial.htm*

buildingSMART International Ltd. (2017*b*), 'Industry Foundation Classes 4x1 - Material Association'. Accessed: 2023-1-31.
URL: *http://standards.buildingsmart.org/IFC/RELEASE/IFC4_1/FINAL/HTML/link/material-association.htm*

buildingSMART International Ltd. (2017*c*), 'Industry Foundation Classes 4x3- IfcPropertySet'. Accessed: 2023-1-31.
URL: *https://standards.buildingsmart.org/IFC/DEV/IFC4_3/RC1/HTML/schema/ifckernel/lexical/ifcpropertyset.htm*

Chandrasekar, P. and Qian, K. (2016), The impact of data preprocessing on the performance of a naive bayes classifier, *in* '2016 IEEE 40th Annual Computer Software and Applications Conference (COMPSAC)', Vol. 2, pp. 618–619.

Chen, J., Hu, Y., Liu, J., Xiao, Y. and Jiang, H. (2019), 'Deep short text classification with knowledge powered attention'.

Ester, M., Kriegel, H.-P., Sander, J. and Xu, X. (1996), A density-based algorithm for discovering clusters in large spatial databases with noise, *in* 'Knowledge Discovery and Data Mining'.

Ferrone, L. and Zanzotto, F. M. (2019), 'Symbolic, distributed, and distributional representations for natural language processing in the era of deep learning: A survey'.

Gensim (n.d.), 'Comparison of fasttext and word2vec'. Accessed: 2023-4-25.
URL: *https://github.com/RaRe-Technologies/gensim/blob/develop/docs/notebooks/Word2Vec_FastText_Comparison.ipynb*

Gensim Documentation (n.d.), 'Gensim documentation - FastText model'. Accessed: 2023-4-25.
URL: *https://radimrehurek.com/gensim/auto_examples/tutorials/run_fasttext.html*

Glinz, M. (2007), On non-functional requirements, *in* '15th IEEE International Requirements Engineering Conference (RE 2007)', pp. 21 – 26.

Gonzalez, Z. and Carlos, V. (2019), Towards explaining the effects of data preprocessing on machine learning, *in* '2019 IEEE 35th International Conference on Data Engineering (ICDE)', pp. 2086–2090.

Grutters, B. (2022), 'Industry Foundation Classes (IFC) – An Introduction'. Accessed: 2023-2-22.
URL: *https://technical.buildingsmart.org/standards/ifc/*

Guyon, I. and Elisseeff, A. (2006), *Feature Extraction Preface*, Springer Berlin Heidelberg, Berlin, Heidelberg.
URL: *https://doi.org/10.1007/978-3-540-35488-8_1*

Hölzing, J. A. (2008), *Die Kano-Theorie der Kundenzufriedenheitsmessung*, Gabler Verlag Wiesbaden.

Industry Foundation Classes (2017). Accessed: 2023-1-31.
URL: *http://standards.buildingsmart.org/IFC/RELEASE/IFC4_1/FINAL/HTML*

Joulin, A., Grave, E., Bojanowski, P. and Mikolov, T. (2016), 'Bag of tricks for efficient text classification'.

Ken, S. and Jeff, S. (2020), 'The scrum guide'.
URL: *https://scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-US.pdf*

Laakso, M. and Kiviniemi, A. O. (2012), 'The IFC standard: A review of history, development, and standardization, information technology', *J. Inf. Technol. Constr.* **17**(9), 134–161.

Le, Q. V. and Mikolov, T. (2014), 'Distributed representations of sentences and documents'.

Liu, D. C. and Nocedal, J. (1989), 'On the limited memory bfgs method for large scale optimization', *Mathematical Programming* **45**, 503–528.

Lockley, S., Benghi, C. and Černý, M. (2017), 'Xbim.Essentials: A library for interoperable building information applications', **2**(20), 473.
URL: *http://joss.theoj.org/papers/b23bed93a0377b4f4317d0583b4d2c5e*

Martin, R. C. and Coplien, J. O. (2009), *Clean code: a handbook of agile software craftsmanship*, Prentice Hall, Upper Saddle River, NJ [etc.].
URL: *https://www.amazon.de/gp/product/0132350882/ref=oh_details_o00_s00_i00*

Microsoft (2021), 'Auswählen eines Algorithmus für maschinelles Lernen - Azure Machine Learning'. Accessed: 2023-05-02.
URL: *https://learn.microsoft.com/de-de/azure/machine-learning/how-to-select-algorithms*

Microsoft (2022*a*), 'Auswählen eines Algorithmus für maschinelles Lernen - Azure Machine Learning'. Accessed: 2023-3-10.
URL: *https://learn.microsoft.com/de-de/azure/machine-learning/how-to-select-algorithms*

Microsoft (2022*b*), 'What is ML.NET and how does it work?'. Accessed: 2023-5-02.
URL: *https://learn.microsoft.com/en-us/dotnet/machine-learning/how-does-mldotnet-work*

Microsoft (2022*c*), 'What is ml.net and how does it work?'. Accessed: 2023-5-02.
URL: *https://learn.microsoft.com/en-us/dotnet/machine-learning/how-does-mldotnet-work*

Microsoft (2022*d*), 'Windows presentation foundation (WPF)'. Accessed: 2023-2-10.
URL: *https://github.com/dotnet/wpf*

Microsoft (n.d.*a*), 'Lbfgsmaximumentropymulticlasstrainer class'. Accessed: 2023-5-02.
URL: *https://learn.microsoft.com/en-us/dotnet/api/microsoft.ml.trainers.lbfgsmaximumentropymulticlasstrainer?view=ml-dotnet*

Microsoft (n.d.*b*), 'Lbfgsmaximumentropymulticlasstrainer class'. Accessed: 2023-5-02.
URL: *https://learn.microsoft.com/en-us/dotnet/api/microsoft.ml.trainers.lbfgsmaximumentropymulticlasstrainer?view=ml-dotnet*

Microsoft (n.d.*c*), 'Multiclassclassificationmetrics class'. Accessed: 2023-5-02.
URL: *https://learn.microsoft.com/en-us/dotnet/api/microsoft.ml.data.multiclassclassificationmetrics?view=ml-dotnet*

Microsoft (n.d.*d*), 'Sdcalogisticregressionbinarytrainer class'. Accessed: 2023-5-02.
URL: *https://learn.microsoft.com/en-us/dotnet/api/microsoft.ml.trainers.sdcalogisticregressionbinarytrainer?view=ml-dotnet*

Microsoft (n.d.*e*), 'Sdcamulticlasstrainerbase<tmodel> class'. Accessed: 2023-5-02.
URL: *https://learn.microsoft.com/en-us/dotnet/api/microsoft.ml.trainers.sdcamulticlasstrainerbase-1?view=ml-dotnet*

Miller, T. (2017), 'Explanation in Artificial Intelligence: Insights from the Social Sciences'.
URL: *https://arxiv.org/abs/1706.07269*

Molnar, C. (2022), *Interpretable Machine Learning*, 2 edn.
URL: *https://christophm.github.io/interpretable-ml-book*

.NET Foundation and Contributors (n.d.), 'ASP.NET core'. Accessed: 2023-3-20.
URL: *https://github.com/dotnet/aspnetcore/blob/main/README.md*

Nooralahzadeh, F., Øvrelid, L. and Lønning, J. T. (2018), Evaluation of domain-specific word embeddings using knowledge resources, *in* 'Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)', European Language Resources Association (ELRA), Miyazaki, Japan.
URL: *https://aclanthology.org/L18-1228*

OpenAI (2022), 'Introducing ChatGPT'. Accessed: 2023-4-24.
URL: *https://openai.com/blog/chatgpt*

OpenAI (n.d.*a*), 'About openai'. Accessed: 2023-5-09.
URL: *https://openai.com/about*

OpenAI (n.d.*b*), 'Api reference'. Accessed: 2023-5-09.
URL: *https://platform.openai.com/docs/api-reference/introduction*

OpenAI (n.d.*c*), 'Pricing'. Accessed: 2023-5-09.
URL: *https://openai.com/pricing*

ORCA Software GmbH (n.d.), 'ORCA helpdesk - ORCA AVA 25 - Kostengliederungen als Basis für das Kostenmanagement'. Accessed: 2023-2-1.
URL: *https://helpdesk.orca-software.com/Solution/AVA25/Content/Kontexthilfe-337_8277*

Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L.,

Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J. and Lowe, R. (2022), 'Training language models to follow instructions with human feedback'.

Quintanilla, L. (2022), 'Introducing the ml.net text classification api (preview)'. Accessed: 2023-5-02.
URL: *https://devblogs.microsoft.com/dotnet/introducing-the-ml-dotnet-text-classification-api-preview/*

Radford, A. (2018), 'Improving language understanding with unsupervised learning'.
URL: *https://openai.com/research/language-unsupervised*

Řehůřek, R. and Sojka, P. (2010), Software Framework for Topic Modelling with Large Corpora, *in* 'Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks', ELRA, Valletta, Malta, pp. 45–50. http://is.muni.cz/publication/884893/en.

Rogel-Salazar, J. (2022), 'Transformers models in machine learning: Self-attention to the rescue'. Accessed: 2023-4-19.
URL: *https://www.dominodatalab.com/blog/transformers-self-attention-to-the-rescue*

scikit-learn developers (n.d.), 'Clustering'. Accessed: 2023-4-27.
URL: *https://scikit-learn.org/stable/modules/clustering.html*

Shah, F. P. and Patel, V. (2016), A review on feature selection and feature extraction for text classification, *in* '2016 International Conference on Wireless Communications, Signal Processing and Networking (WiSPNET)', pp. 2264–2268.

Shalev-Shwartz, S. and Zhang, T. (2013), 'Stochastic dual coordinate ascent methods for regularized loss minimization'.

Shannon, C. E. (1948), 'A mathematical theory of communication', *Bell System Technical Journal* **27**(3), 379–423.
URL: *https://onlinelibrary.wiley.com/doi/abs/10.1002/j.1538-7305.1948.tb01338.x*

Szegedy, C., Zaremba, W., Sutskever, I., Bruna, J., Erhan, D., Goodfellow, I. and Fergus, R. (2013), 'Intriguing properties of neural networks'.
URL: *https://arxiv.org/abs/1312.6199*

Thomas, Baumanns and Dr. Philipp-Stephan, Freber and Dr. Kai-Stefan, Schober and Dr. Florian, Kirchner (2016), 'Bauwirtschaft im Wandel - Trends und Potenziale bis 2020'.

Thomas, L., Yoshinobu, A., James, F., Juha, H., Kari, K., Kent, R., Stefan, R. and buildingSMART International Ltd. (2007), 'IfcMaterialList'. Accessed: 2023-1-31.
URL: *https://standards.buildingsmart.org/IFC/RELEASE/IFC2x3/TC1/HTML/ifcmaterialresource/lexical/ifcmateriallist.htm*

Uysal, A. K. and Gunal, S. (2014), 'The impact of preprocessing on text classification', *Information Processing & Management* **50**(1), 104–112.
URL: *https://www.sciencedirect.com/science/article/pii/S0306457313000964*

van Berlo, L. (2022), 'IFC Specifications Database'. Accessed: 2023-2-22.
URL: *https://technical.buildingsmart.org/standards/ifc/ifc-schema-specifications/*

Wang, J., Wang, Z., Zhang, D. and Yan, J. (2017), Combining knowledge with deep convolutional neural networks for short text classification, *in* 'Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, IJCAI-17', pp. 2915–2921.
URL: *https://doi.org/10.24963/ijcai.2017/406*

Xbim Ltd. (n.d.), 'Xbim toolkit'. Accessed: 2023-1-31.
URL: *https://docs.xbim.net/research/history.html*

Zhu, Q. and Luo, J. (2022), 'Generative pre-trained transformer for design concept generation: An exploration', *Proceedings of the Design Society* **2**, 1825–1834.